의약품 개발 전주기에 걸친

AI의 활용

2026. 3. 26

김화종 | K-MELLODDY 사업단장
hjkim3@gmail.com

목차

01 AI의 이해

02 화합물 의약품 개발과 AI

03 바이오 의약품 개발과 AI

04 AI 기술 트렌드

PART 1

AI의 이해

AI 정의

📌 AI 모델

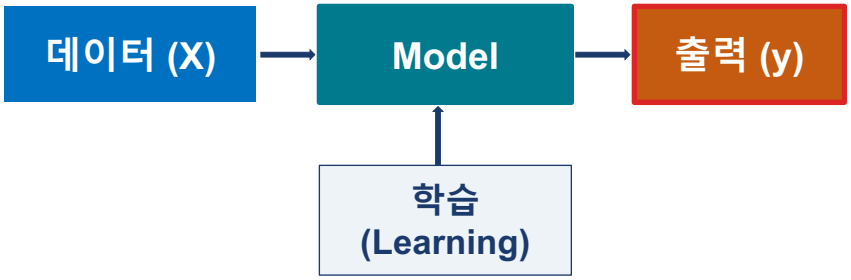
AI는 입력 데이터(X)로부터 원하는 출력(y)을 얻는 **모델**로 구현된다. 모델은 구조(알고리즘)와 파라미터로 구성된다. $Y = W \cdot X + b$

⚠️ 수식과 논리 모델의 한계

수식이나 논리는 명쾌하지만 화학 및 생명현상·제약 공정처럼 복잡한 실제 세계를 모델링하는 데 한계가 있다.

🤖 Machine Learning

데이터를 기반으로 최적의 성능을 내는 모델 파라미터를 학습하는 방식을 **Machine Learning**이라고 하며 현재 AI 구현에 널리 사용된다



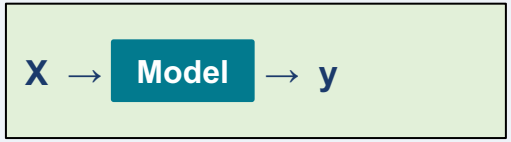
AI의 목적

- 🎯 예측 — 레이블(y) 예측
- 🛒 추천 — 최적 상품/처방/후보 추천
- 🔧 최적화 — 최적 설계·제어
- 📐 표현형 학습 — X 특성 벡터 학습
- ✨ 생성 — 유사 X 데이터 생성

AI의 목적

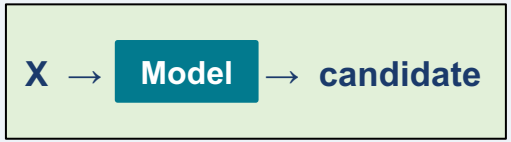
예측 모델
Predictive Model

입력 데이터(X, feature)를 보고 출력(y, 레이블) 예측
→ **이상치(OOS) 예측, 배치 품질 예측**



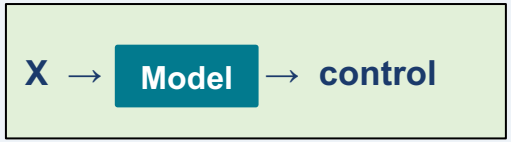
추천 모델
Recommender Model

최적의 상품·처방·후보 추천
→ **신약 후보 추천, CAPA(시정 및 예방 조치) 대응책 추천**



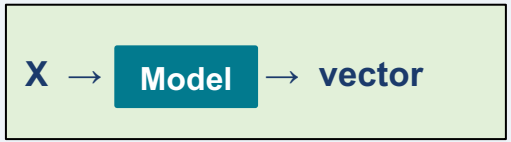
최적화 모델
Prescriptive Model

현재 조건(X)에서 최적 설계·제어 변수 도출
→ **공정 핵심변수(CPP) 최적화, 배합 최적 설계**



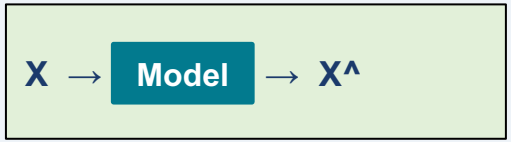
표현형 학습
Representation Learning

X에 내재된 정보를 학습하여 feature 표현 vector 추출
→ **파운데이션 모델(LLM), 분자 임베딩**

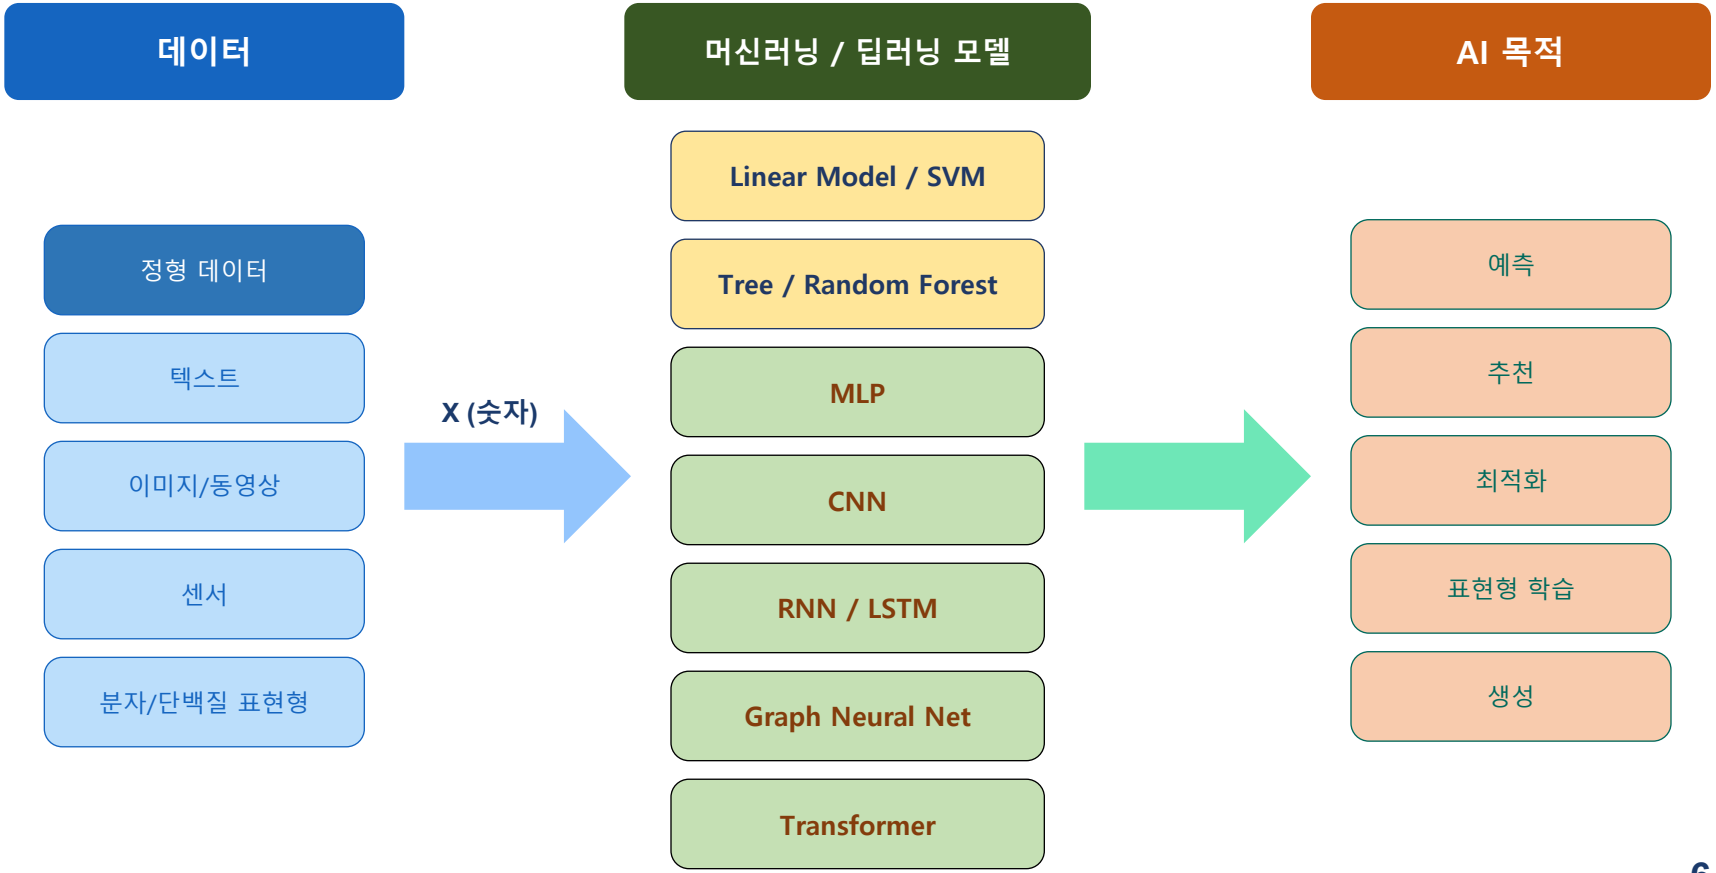


생성 모델
Generative Model

파운데이션 모델을 이용하여 원하는 데이터(X^) 생성
→ **자연어 처리, 분자 생성 모델, 단백질 구조 생성**



AI 구현 체계


데이터
머신러닝 / 딥러닝 모델
AI 목적
정형 데이터
텍스트
이미지/동영상
센서
분자/단백질 표현형
X (숫자)
Linear Model / SVM
Tree / Random Forest
MLP
CNN
RNN / LSTM
Graph Neural Net
Transformer
예측
추천
최적화
표현형 학습
생성

AI 주요 기술

머신러닝 모델	데이터에 잠재된 패턴을 파악하여 새로운 데이터의 특성을 예측, 분류하거나 최적값 추천, 최적화에 사용 (선형모델, SVM, 결정트리, 랜덤포레스트, 부스팅 모델 등)
딥러닝 모델	동일한 물리적 특성을 가진 다량의 신호 (이미지, 텍스트, 사운드, 센서 등)의 특성 추출에 우수한 성능을 얻는 머신러닝 모델 (MLP, CNN, RNN, Graph Network, Transformer)
파운데이션 모델	입력 데이터의 표현형을 학습한 모델로, LLM(Large Language Model)이 대표적인 파운데이션 모델
Science LLM	화학, 생물학, 물리학, 의학, 약학 등을 이해하고 처리하는 지능을 가진 파운데이션 모델
RAG **Agentic AI**	- Retrieval-Augmented Generator: LLM에 외부 데이터를 추가 제공하여 성능 개선 - LLM을 이용하여 복합적인 업무를 **자동으로 처리**하는 기능

딥러닝 모델

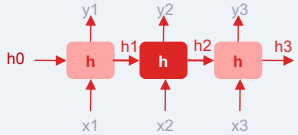
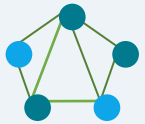
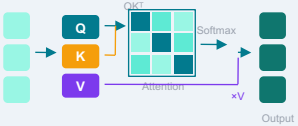
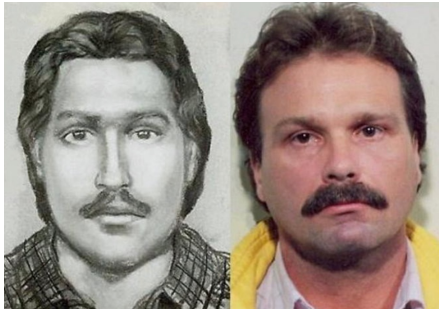
MLP	Multi Layer Perceptron. 완전 연결(Fully Connected) 레이어들의 다층 구조로 **비선형적인** 입출력 관계 예측에 주로 사용	
CNN	Convolution Neural Network. 2차원 이미지, 1차원 시계열 데이터의 **패턴 추출**에 주로 사용	
RNN (LSTM)	Recurrent Neural Network (Long Short Term Memory). 순환 구조로 **시퀀스 데이터**· 텍스트 분석 · SMILES 분석 등에 활용	
Graph Model	노드와 엣지로 구성된 그래프 형태의 모델로 **분자 구조**, 사회관계망 등의 분석에 사용	
Transformer	입력 시퀀스를 블록 단위로 나누어 Self-Attention을 계산하는 방식으로 텍스트, 시퀀스 데이터의 **문맥 파악** 성능을 향상. LLM의 성능 고도화 (BERT, GPT)	

Image Representation Example





미국 로이스깁슨 - 1300명 범인 검거로 기네스북 등재

몽타주는 이미지를 수십 개의 features(숫자)로 표현하는 것

- 안경:0, 눈썹길이:0.8, 눈썹모양: 2, 코:0.7, 입술:0.4, 턱: 0.4, 귀:3,...
- 얼굴 = (0, 0.8, 2, 0.7, 0.4, 0.4, 3, ..., 0.6) : vector로 표현 가능

이미지를 임베딩 벡터로 표현 가능

- 벡터 차원을 높이면 매우 정교하게 얼굴을 묘사할 수 있다
- 벡터 값을 바꾸면 쉽게 다른 얼굴 표현 가능함 (이미지 생성 모델)

PART 2

화합물 의약품 개발과 AI

9단계 개발 주기와 단계별 핵심 AI 모델

화합물 의약품 개발 주기



1 질병 이해

Disease Biology

Small Molecule

목 적

질병 분자기전·세포상태를 이해하여 "어떤 생물학적 문제를 풀 것인가"를 정의. 단일 유전자가 아닌 네트워크·세포 수준의 통합 분석이 핵심.

핵심 이슈 & 트렌드

Single-cell foundation model + 멀티모달 학습 확산. 데이터 표준화·생물학적 해석 가능성이 최대 과제.

대표 AI 모델

Geneformer
Single-cell 전사체 기반 생물학 foundation model

scGPT
Single-cell / Multi-omics 생성형 foundation model

멀티오믹스 Transformer
유전체·전사체·단백체 통합 학습

지식그래프 GNN
질병–유전자–경로 관계 추론

바이오 LLM
논문·특허·DB에서 기전·바이오마커 추출

주요 데이터

유전체 변이 · single-cell RNA-seq · 단백체/인산화체 · 후성유전체(메틸화) · 병리이미지
임상 코호트 · 대사체(metabolomics) · 마이크로바이옴 · 환자 표현형 · RWD/RWE

2 타깃 발굴

Target Discovery

Small Molecule

목 적

질병기전 분석 결과로 개입 지점(유전자·단백질·경로)을 선택. 질병 수정 효과와 druggability를 함께 판단.

핵심 이슈 & 트렌드

GNN+foundation model+문헌 LLM 결합 추세. 정확도보다 설명가능성·실험 검증 가능성이 중요.

대표 AI 모델

TxGNN
질병–유전자–약물 그래프 기반 타깃/재창출

KG Embedding
Knowledge Graph 신규 링크 예측

Graph Neural Network
질병–타깃 네트워크 추론

Causal Bayesian Network
원인경로 추론·개입 효과 예측

LLM Literature Mining
타깃 근거 자동 요약 및 점수화

주요 데이터

질병-유전자 연관 · PPI 네트워크 · CRISPR 스크린 · GWAS 결과 · Pathway/Ontology

공공 target DB · druggability 평가 · 문헌 마이닝 · 환자 유전체 프로파일

3 선도물질 발굴

Hit Discovery

Small Molecule

목 적

선택한 타깃에 결합 가능한 초기 후보 분자(hit) 탐색. 실험 대상을 줄여 스크리닝 효율을 높이는 것이 핵심.

핵심 이슈 & 트렌드

대규모 사전학습 분자모델 + 물리기반 도킹 결합 증가. 실험 우선순위 선택 도구로 활용.

대표 AI 모델

ChemBERTa
SMILES 기반 화학 언어모델

GROVER
대규모 분자 그래프 Transformer

Chemprop (D-MPNN)
분자 물성/활성 예측

MolCLR
Self-supervised 분자 표현학습

도킹 보정 GNN
Virtual screening 우선순위화

주요 데이터

화합물 라이브러리 · 3D conformer · 도킹 점수 · HTS 결과 · 결합친화도

단백질 구조(cryo-EM) · FBDD fragment · 가상 스크리닝 · ADME 필터 · 약물유사성(Lipinski)

4 리드 최적화

Lead Optimization

Small Molecule

목 적

Hit를 리드로 전환하기 위해 효능·선택성·용해도·대사안정성·독성·합성 용이성을 개선하는 과정. 다목적 최적화가 핵심.

핵심 이슈 & 트렌드

예측 모델과 생성 모델 활용. 합성가능성·특허회피·실험 피드백 반영한 closed-loop 설계가 핵심.

대표 AI 모델

생성형 Transformer
분자 서열 기반 구조 생성/수정

Diffusion Model
제약조건 기반 분자 구조 생성

VAE Molecule Generator
잠재공간 분자 탐색 및 최적화

RL 분자 설계
강화학습 기반 다목적 최적화

단백질-리간드 멀티모달
구조+활성 동시 학습 모델

주요 데이터

SAR 데이터 · ADME 프로파일 · in vitro 독성 · co-crystal 구조 · 합성 경로

선택성 패널 · 용해도/투과성 · 대사안정성(microsome) · CYP 저해/유도 · hERG 채널 활성

5 비임상

Preclinical Development

Small Molecule

목 적

독성·PK/PD·안전성을 평가해 임상 진입 가능성 판단. "좋은 후보 찾기"보다 나쁜 후보를 조기 탈락시키는 것이 중요.

핵심 이슈 & 트렌드

멀티태스크 ADMET + 구조·오믹스·이미지 통합 멀티모달 비임상 모델 개발 중.

대표 AI 모델

DeepTox / ADMET 모델
다중 독성 endpoint 동시 예측

멀티태스크 GNN ADMET
ADME·독성 통합 멀티태스크 학습

PK/PD Neural ODE
노출-반응 동역학 연속 모델링

Bayesian PK 모델
불확실성 정량화 PK/PD 예측

DTox (knowledge-guided)
독성 경로 기반 mechanistic 예측

주요 데이터

in vitro 독성 · hERG/CYP/DDI · PK 프로파일 · 조직병리 이미지 · omics biomarker

동물실험 데이터 · GLP 독성 보고서 · 생식독성 · 유전독성(Ames) · 면역독성 패널

6 규제 대응

Regulatory Affairs

Small Molecule

목 적

AI 결과와 데이터를 제출 가능한 근거로 변환. 허가 심사 관점에서 신뢰성·추적성·변경관리 확보.

핵심 이슈 & 트렌드

FDA 2025 AI Draft Guidance 발표. 목적 적합성 ·human oversight·변경관리가 핵심.

대표 AI 모델

RAG 기반 규제 QA
가이드라인 기반 질의응답 시스템

LLM 문서 인텔리전스
CTD/CSR/briefing package 초안 지원

지식그래프 Traceability
데이터 계보 추적 및 근거 관리

Conformal Prediction
불확실성 정량화 및 신뢰 구간 제공

Rule+LLM Checker
21 CFR 형식 자동 준수 검토

주요 데이터

비임상/임상 원천 데이터 · 모델 학습/검증 로그 · 변경이력 · 규제 가이드라인 · 제출 dossier

ALCOA+ 준수 기록 · 감사 추적(audit trail) · 전자서명/승인 이력 · SaMD 분류 근거 · 위험관리 파일(ISO 14971)

7 임상

Clinical Development

Small Molecule

목 적

환자 선별·시험 설계·운영 효율화·성공확률 향상. "누구를 어떤 기준으로, 얼마나 빠르게 연결할지"가 핵심.

핵심 이슈 & 트렌드

LLM 기반 trial matching 확산. 설명가능성·개인정보·기관별 데이터 이질성이 주요 이슈.

대표 AI 모델

TrialGPT
LLM 기반 환자–임상시험 매칭

PRISM
Semantic clinical trial matching

Med-BERT
EHR 사전학습 환자 표현 모델

RETAIN
해석 가능한 환자 시계열 예측

Survival DL 모델
반응·탈락·생존 예측 딥러닝

주요 데이터

EHR · 임상시험 프로토콜 · inclusion/exclusion criteria · 영상/병리 결과 · ePRO/wearable
유전체 프로파일 · 바이오마커 측정값 · PK/PD 모델링 · 환자 보고 결과(PRO) · 디지털 표현형

8 제조

Manufacturing / CMC

Small Molecule

목 적

공정 안정화·품질 예측·일탈 조기 탐지·배치 간 변동성 최소화. 공정 이해(process understanding) 향상.

핵심 이슈 & 트렌드

디지털 트윈·멀티모달 데이터 통합. 데이터 무결성·밸리데이션·모델 재학습 통제가 핵심.

대표 AI 모델

Autoencoder 이상탐지
배치-to-배치 편차 조기 탐지

LSTM/Transformer 시계열
공정 drift·일탈 예측

Soft Sensor ML
직접 측정 어려운 CQA 실시간 추정

Digital Twin + ML
가상 공정 시뮬레이션 및 최적화

Computer Vision
외관검사·결함 탐지 자동화

주요 데이터

배치 기록 · CPP(핵심 공정 파라미터) · CQA(품질 속성) · PAT(Process Analytical Technology) 센서 · LIMS/MES
설비 로그 · 원자재 CoA · 환경 모니터링 · 일탈/CAPA(Corrective Action and Preventive Action) 기록 · 공정 검증(PV) 데이터

9 시판 후 관리

Post-Market / Pharmacovigilance

Small Molecule

목 적

실제 사용 환경에서 안전성 탐지. RWD/RWE 기반 희귀 부작용·장기 안전성·실사용 효과 파악.

핵심 이슈 & 트렌드

NLP/LLM+지식그래프+RWD 인과추론 급증. Class imbalance·데이터 편향·signal 검증이 핵심 과제.

대표 AI 모델

NLP 기반 ADE/ADR 추출

Adverse Drug Event (약물 유해 사건), ADR = Adverse Drug Reaction (약물 유해 반응)

지식그래프 신호탐지

다중 소스 통합 안전성 신호 탐지

LLM 케이스 Triage

케이스 요약·우선순위 자동화

RWD 예측 모델

실사용 안전성/효과 인과추론

주요 데이터

자발적 부작용 보고 · EHR/claims · 처방 데이터 · 환자 신고 · 소셜미디어 모니터링 · PBRER(Periodic Benefit-Risk Evaluation Report (정기적 유익성-위험성 평가 보고서) · 신호 탐지 통계 · RWE 효과성 분석

PART 3

바이오 의약품 개발과 AI

항체·재조합단백질·세포유전자치료제 개발에서의 AI 활용

바이오 의약품 개발 주기



Biologics와 화합물 의약품 상이

Small Molecule vs. Biologics		
개발 단계	**Small Molecule**	**Biologics**
후보물질 발굴	화합물 library, docking, HTS	**항체/단백질 서열, epitope(항체결합부위), phage display**
후보 최적화	효능·용해도·대사안정성·독성·합성	**친화도·선택성·안정성·면역원성·developability**
비임상	독성·ADMET·PK/PD 중심	**면역원성·biodistribution·종간 번역성**
CMC/공정개발	공정 안정화·품질 예측	**세포주 개발·배양·정제·CQA(Critical Quality Attribute)**

3 후보물질 발굴

Candidate Discovery (Biologics)

Biologics

목 적

선정 타깃에 대해 항체·재조합단백질·세포유전자치료제 후보 탐색. 결합력뿐 아니라 기능성과 developability까지 함께 고려.

핵심 이슈 & 트렌드

서열–구조–기능 통합 설계가 중요. Foundation model+구조예측+생성형 AI 결합으로 더 나은 후보 탐색.

대표 AI 모델

Protein Language Model
기능·구조·binding 가능성 표현 foundation model

Antibody Foundation Model
항원 결합력, human-likeness, developability 예측

Structure Prediction Model
Antigen-antibody 3D complex 구조 예측

Generative Protein Design
원하는 특성을 만족하는 항체/단백질 서열 생성

Multimodal Binder Prediction
Multi-modal 정보로 binder 랭킹

주요 데이터

항원 서열 · 항원 구조 · 항체 서열 repertoire · epitope mapping · phage display

발현성/안정성 · 결합 kinetics(SPR) · 세포 기반 활성 · in silico humanization · 특허 서열 DB

4 후보 최적화

Candidate Optimization (Biologics)

Biologics

목 적

초기 후보의 친화도·선택성·안정성·면역원성·developability를 동시 개선. 임상과 제조로 이어질 수 있는 후보로 발전.

핵심 이슈 & 트렌드

친화도뿐 아니라 안정성·면역원성·제조가능성까지 다목적 최적화. 생성형 AI + 실험 피드백 closed-loop 중요.

대표 AI 모델

Ab Sequence Optimization
CDR mutation으로 affinity·stability 동시 향상

Diffusion Protein Design
Antibody/protein variant 생성 diffusion 모델

Binding Affinity Prediction
Antigen-antibody interaction 결합강도 예측

Immunogenicity Prediction
T-cell epitope·MHC binding 면역원성 사전 평가

Developability Prediction
응집성·점도·발현량 등 제조 친화 특성 평가

주요 데이터

변이 라이브러리 · binding affinity · neutralization/potency · 열안정성 · 응집성

면역원성 epitope · glycosylation 패턴 · Fc effector 기능 · 점도/제형 적합성 · 교차반응성 패널

5 비임상 개발

Preclinical (Biologics)

Biologics

목 적

후보 biologics의 효력·독성·PK/PD·면역원성을 평가해 임상 진입 가능성 판단.

핵심 이슈 & 트렌드

면역원성·종간 번역성·biodistribution이 특히 중요. 멀티모달 비임상 모델(구조+오믹스+이미지+PK/PD) 개발 중.

대표 AI 모델

Multitask Toxicity Model
여러 독성 endpoint 동시 학습·예측

PK/PD Neural ODE
Exposure–response dynamics 연속 모델링

Immunogenicity Risk Model
ADA 발생가능성·immune response 패턴 사전 추정

Digital Pathology Model
조직병리 이미지에서 효력·독성 signal 추출

Cross-species Translation
Animal-to-human translation 임상 예측가능성 향상

주요 데이터

in vitro 효력 · 동물실험 데이터 · PK 프로파일 · PD 바이오마커 · 조직병리 이미지

ADA 데이터 · 독성 용량반응 · 사이토카인 방출 · 조직 교차반응성 · GLP 독성 보고서

6 CMC / 공정개발

CMC / Process Development

Biologics

목 적

세포주 개발·배양·정제 공정·제형·CQA를 확립하여 품질 일관성, 생산성, 공정 안정성을 확보.

핵심 이슈 & 트렌드

Product is process 특성 강함. Digital twin+soft sensor+데이터 무결성 기반 규제 친화 공정 AI가 부상.

대표 AI 모델

Cell Line Selection Model
Clone screening으로 고생산성·고안정성 cell line 선별

LSTM/Transformer 시계열
배양·정제 공정 drift·편차·수율 변동 예측

Soft Sensor ML
CQA를 공정 센서+CPP로 실시간 추정

Digital Twin Optimization
가상공간에서 공정 재현 후 조건 최적화

Anomaly Detection Autoencoder
Batch-to-batch 변동·공정 이탈 조기 탐지

주요 데이터

세포주 특성 · 배양 조건 · feeding strategy · 정제 공정 · CPP 데이터 · CQA 데이터 · 제형 안정성 · 분석법 밸리데이션 · 스케일업 파라미터 · 바이러스 클리어런스

PART 4

AI 기술 트렌드

멀티모달 · SDL · Agentic AI · 규제 친화 AI · 연합학습

멀티모달 AI



서로 다른 형식(mode)의 데이터를 공통 잠재공간에서 학습하여 모델 성능 향상

Self Driving Lab (SDL)

예측 AI	자동화 로보틱스	디지털 트윈
다음 실험 조건 제안	실험 자동 실행	실시간 공정 반영
베이지안 최적화 Active Learning 가설 수립·우선순위 설정	합성·정제·분석 스크리닝 자동화 오류 없는 실험 실행	실험 결과 가상 모델 즉시 반영·시뮬레이션 폐루프 완성

신약개발 적용:	화합물 합성 최적화 · 제형 개발 · 분석법 개발 · 배양 공정 최적화
대표 사례:	Alan Aspuru-Guzik (Acceleration Consortium), Eli Lilly, AstraZeneca 자동화 합성 플랫폼
GMP 환경 고려:	21 CFR Part 11 전자기록·서명 · GAMP5 검증 · ALCOA+ 데이터 무결성 · 자율 의사결정 감사추적 필수

SDL은 단순 자동화를 넘어 생성형 AI·에이전트 AI와 결합해 비임상·제형·공정 개발 속도와 품질을 크게 개선

Agentic AI

문헌 탐색 에이전트	실험 계획 에이전트	규제 대응 에이전트	데이터 분석 에이전트
타겟·문헌 해석 가설 자동 생성	가설 기반 실험 차시 제안·우선순위	CTD/CSR 초안 작성 규제 Q&A 자동 답변	멀티소스 데이터 복합 추론·보고서

멀티에이전트 시스템: 에이전트들이 협업하여 타깃 발굴→실험 설계→데이터 분석→보고서 작성 자율 수행

GMP 에서의 한계와 대응



환각(Hallucination) 위험

공정 제어·규제 제출에서는 인간 감독(human oversight) 필수



감사추적 필수

에이전트의 모든 결정 과정이 기록되고 검증 가능해야 함



FDA 지침

COU(Context of Use) 명확화와 신뢰성 평가 요구



설명가능성

중요 결정 담당 시 explainability·verifiability 필수

규제 친화적(Trustworthy) AI

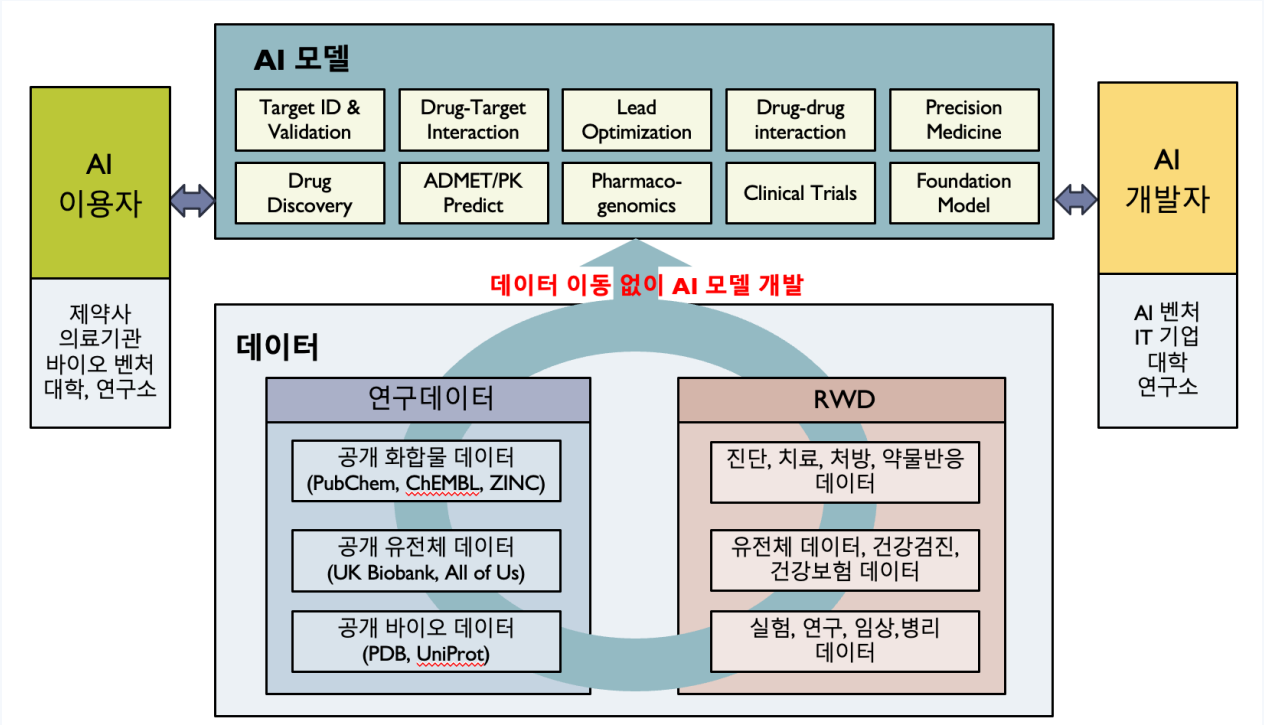
기존 접근	규제 친화적 AI
✗ 최고 성능 모델 추구	✓ 불확실성 정량화 (Conformal Prediction)
✗ 블랙박스 모델 사용	✓ 추적가능성 (Data + Model lineage)
✗ 불확실성 무시·단일 예측값 사용	✓ 변경관리 (CAPA 프로세스 적용)
✗ 데이터 출처·버전 관리 미흡	✓ 재현성·검증 가능성 내장
✗ 감사 대응 한계	✓ 운영 중 성능 저하 모니터링

FDA 2025 AI Draft Guidance — 위험 기반 신뢰성 평가 7단계

1. COU 정의
2. 영향도 평가
3. 신뢰성 목표 설정
4. 평가 계획
5. 모델 개발 및 평가
6. 불확실성 정량화
7. 라이프사이클 관리

Human Oversight 원칙: AI 결과는 전문가 검토 아래 사용해야 하며 환자 안전 의사결정에서 AI 자율 판단 불허

연합학습 기반 협력



현실: 연구용 데이터로 만든 AI 모델을 실세계 데이터에 적용하므로 정확도 한계

해결 방향: 연구용 데이터와 실세계 데이터를 모두 활용하는 AI 모델 필요 → **연합학습(Federated Learning)** 도입

결론

01 **AI는 의약품 개발 전주기에서 활용**

질병 이해부터 시판 후 관리까지, 데이터 기반 AI 모델이 각 단계의 효율과 정확도를 혁신

02 **개별 모델보다 데이터 연결성과 멀티모달 데이터 통합**

전주기 데이터 연계와 멀티모달 통합이 성능 향상의 핵심 조건

03 **규제 친화적 AI - 최고 성능보다 검증·추적·설명 가능한 모델 요구**

FDA 2025 Draft Guidance · ALCOA+ · GxP 준수가 글로벌 진출의 전제 조건

04 **고품질 데이터 협력 활용으로 글로벌 경쟁력 확보 - 한국의 기회**

연합학습으로 데이터 이동 없이 성능이 우수한 AI 모델 협력 개발 (오픈 이노베이션 생태계)

Q & A