제약바이오 AI 기초

김 화 종

K-MELLODDY 사업단장

hjkim3@gmail.com

신약개발 주기와 AI

1 질병 이해·타깃 발굴

오믹스 분석 · 질병 아형 · 바이오마커 · 타깃 예측/검증

2 후보물질 발굴·최적화

가상 스크리닝 · 생성형 분자 설계 · 구조예측(AlphaFold) · ADMET

3 전임상(비임상)

독성 예측 · PK/PD 모델링 · 효능 예측 · 동물실험 대체

4 임상

임상시험 설계 · 코호트 선별 · 디지털 바이오마커 · 약물감시

5 CMC·제조·품질

QbD · 공정 이상탐지 · OOS 예측 · RTRT · 예지보수

6 규제·허가

문서 자동화(eCTD) · FDA/EMA 대응 · GAIP · 모델 검증

7 시판 후

RWE/RWD 분석 · 시판후 안전성 · 시장·환자 인사이트

공통 기술 (파운데이션)

예측형 · 생성형 AI · 연합학습(K-MELLODDY) · 파운데이션 모델 · 멀티모달

예제

- 01 · Colab & LLM 코딩 워밍업
  - Google Colab에서 코드 셀 실행, 라이브러리 설치, pandas로 데이터 열어보기를 익힙니다. "문제 정의 → LLM(Gemini/Claude)에게 코드 요청 → Colab에서 실행·검증" 실무 워크플로우를 몸에 익히는 것이 목표입니다.
- 02 · 회귀로 화합물 용해도 예측
  - "이 분자가 물에 얼마나 녹을까?"를 구조만 보고 AI로 예측합니다. SMILES를 분자 특성값(descriptor)으로 바꾸고 회귀 모델을 학습해, R^2·RMSE로 예측 정확도를 확인하는 대표적 AI 활용 사례입니다.
- 03 · 분류로 '뇌로 가는 약' 예측 (BBB 투과)
  - 치매·우울증 약은 혈액뇌장벽(BBB)을 통과해야 효과가 있습니다. 분자 구조만으로 "뇌로 갈 수 있는가(O/X)"를 판별하는 분류 문제를 다루며, 혼동행렬·재현율·AUC로 회귀와 분류의 차이를 배웁니다.
- 04 · 모델 비교 · 교차검증 · 과적합
  - 여러 머신러닝 모델을 비교하고, 데이터 분할과 교차검증(CV)을 배웁니다. 학습데이터만 잘 맞추는 과대적합의 함정을 진단하고, 스케일링·파이프라인을 배웁니다.

예제

- 05 · RDKit으로 분자 다루기
  - 신약개발 AI의 필수 기본기인 화학정보학을 익힙니다. SMILES ↔ 분자 객체 ↔ 구조 그림 변환, 분자 특성과 Lipinski 5원칙, 분자지문·Tanimoto 유사도, 부분구조 검색 등지 실제 스크리닝 기술을 다룹니다.
- 06 · QSAR: ChEMBL 데이터로 약물 활성 예측
  - "이 분자가 표적 단백질에 얼마나 잘 붙을까?"를 IC50로 예측합니다. 전 세계 표준 생체활성 DB인 ChEMBL의 BACE-1(알츠하이머 표적) 데이터로 QSAR 모델을 만들어, 합성 전에 유망를 고르는 방법을 배웁니다.
- 07 · 가상 스크리닝 (Virtual Screening)
  - 수십만~수백만 개 화합물 라이브러리에서 유망 후보만 걸러내는 실전 파이프라인입니다. 알려진 활성물질과 닮은 분자를 찾는 유사도 검색과 약물유사성·ADMET 필터를 결합한 스크리닝을 구현합니다.
- 08 · 단백질 구조 예측 (AlphaFold / ESMFold)
  - 아미노산 서열만으로 3D 구조를 예측합니다. 노벨화학상을 받은 AlphaFold와 API 한 번으로 구조를 얻는 ESMFold를 사용해, 약이 붙을 자리(pocket)를 찾고 예측 신뢰도(pLDDT)를 해석합니다.

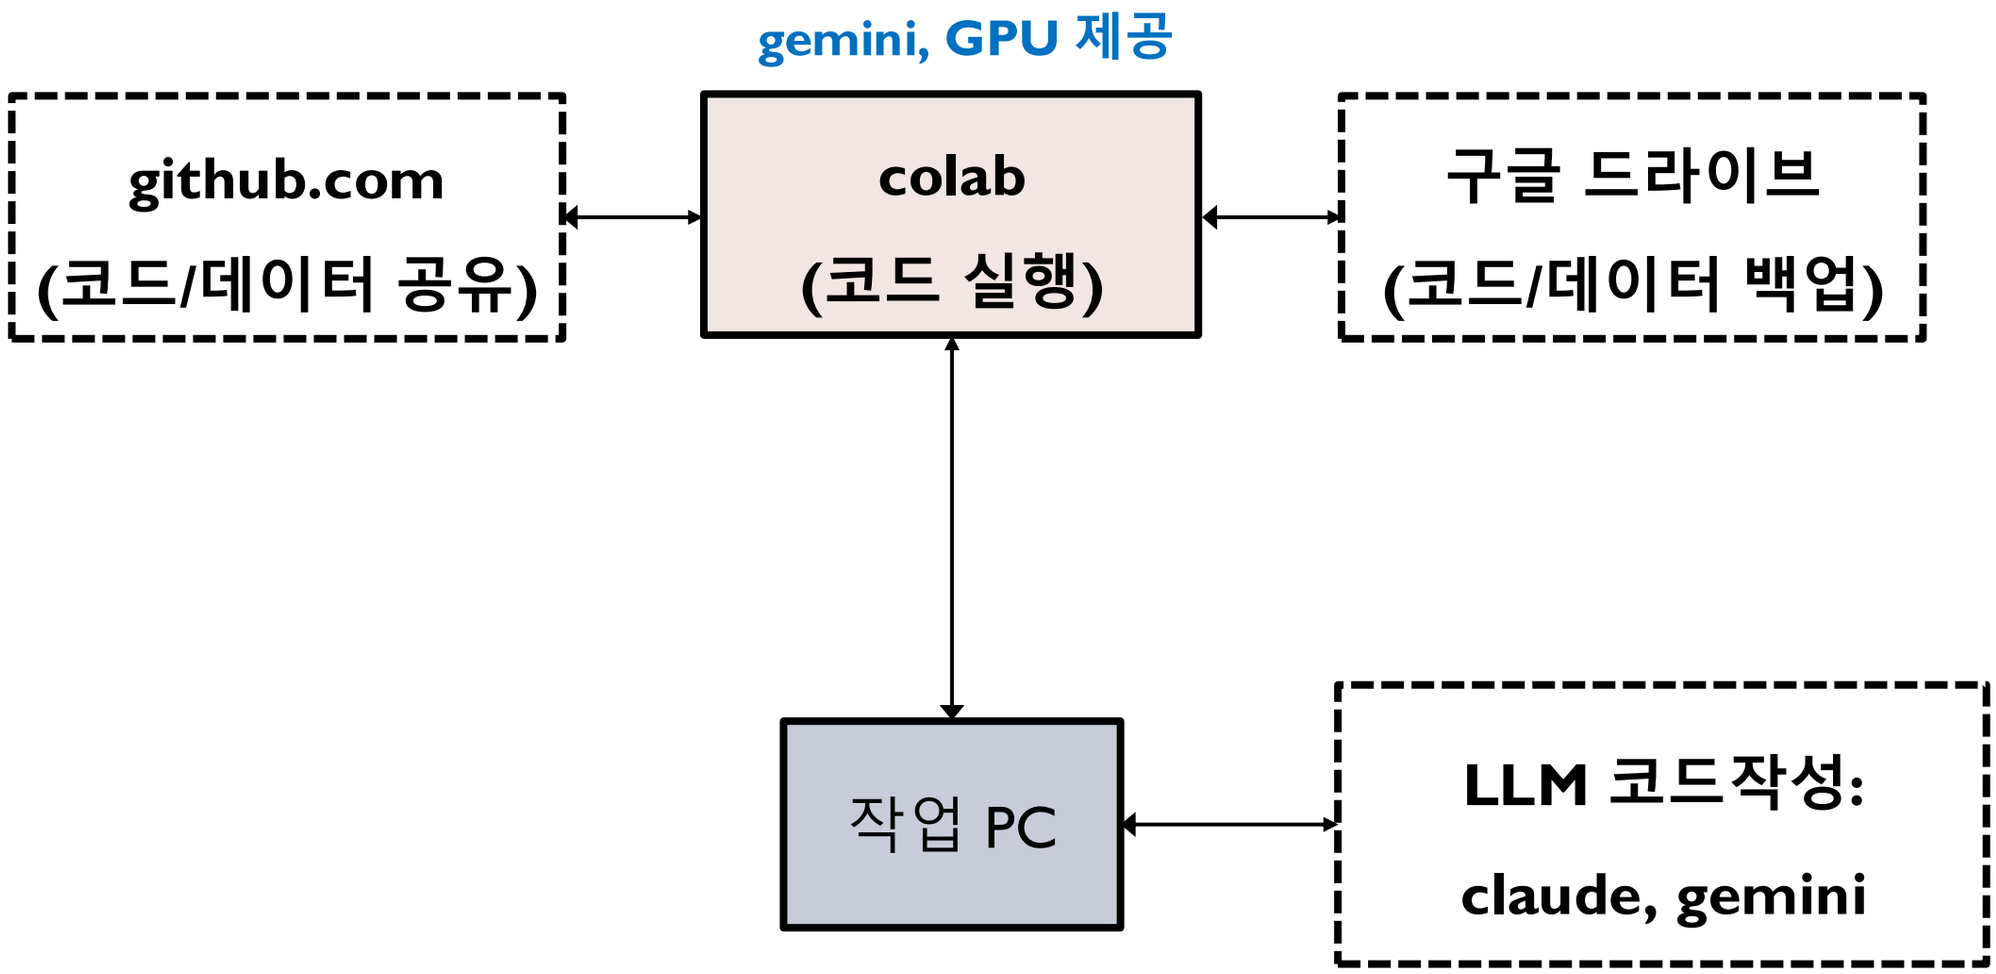
예제

- 09 · 분자 도킹 (AutoDock Vina & DiffDock)
  - 약물이 표적 단백질에 어떤 자세로 얼마나 세게 붙는지 예측하는 구조 기반 신약설계(SBDD)의 핵심입니다. 현장 표준 AutoDock Vina로 결합에너지·결합 자세를 구하고, 최신 딥러닝 도킹 DiffDock을 소개합니다.
- 10 · 화학·바이오 파운데이션 모델 (ChemBERTa & ESM)
  - GPT가 텍스트를 학습하듯, 분자(SMILES)와 단백질(서열)을 대규모로 학습한 파운데이션 모델을 활용합니다. HuggingFace에서 ChemBERTa·ESM-2를 불러와 임베딩을 추출하고, 적은 데이터로도 물성·변이 영향을 예측합니다.
- 11 · 생성형 분자설계 (De novo, MolGPT)
  - 분석을 넘어 AI가 세상에 없던 새 분자를 스스로 설계합니다. SMILES를 학습한 생성모델로 신규 후보를 샘플링하고, RDKit 유효성·약물다움(Lipinski·QED)으로 좁히는 "생성→필터 깔때기"를 경험합니다.
- 12 · 단백질 설계 심화 (ESM 변이 스캐닝)
  - 항체·효소를 "어디를 바꾸면 좋은지" ESM-2에게 묻습니다. 단일 forward pass로 서열 전체의 변이 점수 지도(deep mutational scan)를 만들어 히트맵으로 보존/유연 위치를 구분하고, 실험 우선순위 후보를 뽑습니다.

예제

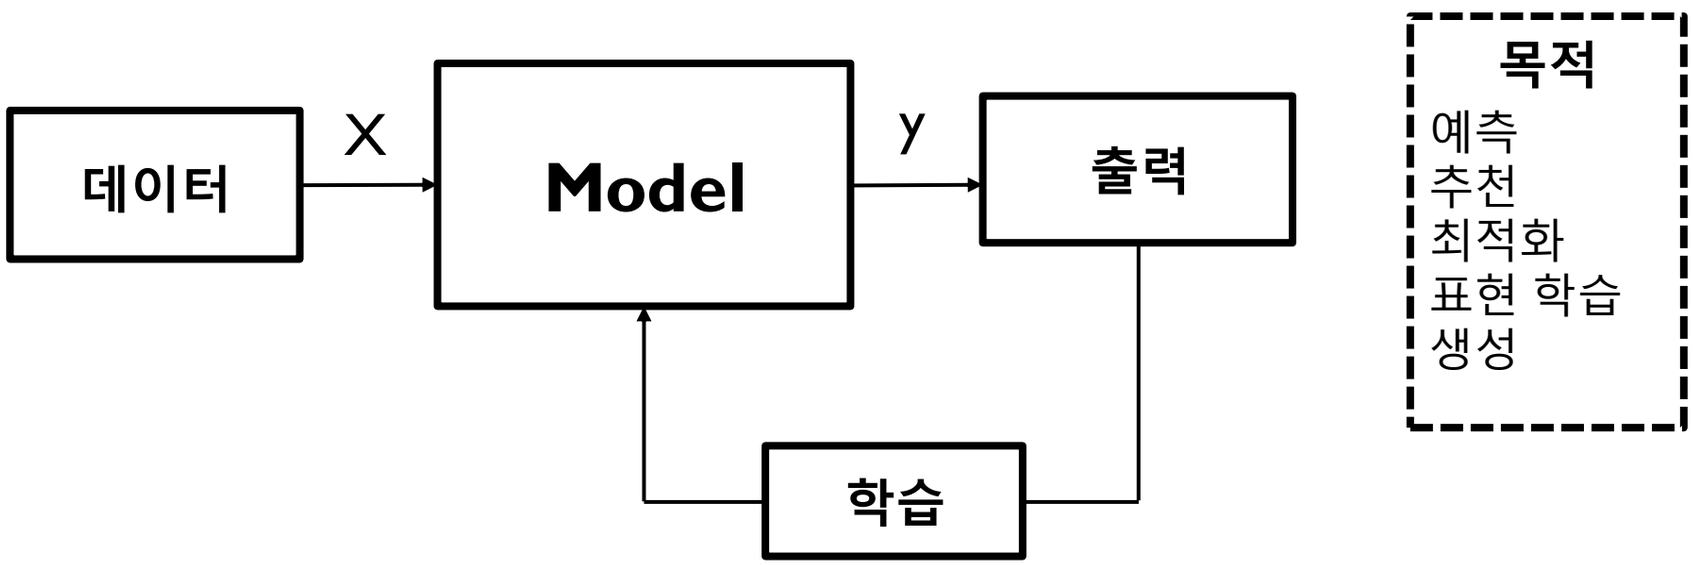
- 13 · 배치 수율 예측 & OOS 조기경보
  - 발효/합성 공정의 센서값(온도·pH·산소·교반 등)으로 최종 품질을 미리 예측합니다. 규격이탈(OOS) 배치를 일찍 잡아 손실과 조사를 줄이는 스마트 제조/PAT의 핵심을, 페니실린 발효 시뮬레이션 데이터로 실습합니다.
- 14 · SPC 관리도 + 다변량 이상탐지
  - GMP 제조의 필수인 통계적 공정관리(SPC)와 AI 이상탐지를 함께 다룹니다. 변수 하나씩 보는 관리도의 한계를 넘어, 각 변수는 정상이지만 조합이 비정상인 경우를 다변량 이상탐지로 잡아냅니다.
- 15 · 예지보수 (Predictive Maintenance)
  - 생물의약품 제조 핵심 설비인 동결건조기의 센서 데이터로 고장까지 남은 배치 수(RUL)를 예측합니다. 회귀·분류 모델과 LSTM으로 상태 기반 최적 정비 시점을 찾아, 과잉 교체 없이 비용을 낮추는 예지보수를 구현합니다.
- 16 · 페니실린 공정 데이터 탐색 (QbD/CPP/CQA)
  - IndPenSim 벤치마크(100개 배치·11만여 샘플)로 의약품 제조 공정 데이터를 탐색합니다. 핵심 공정변수(CPP)와 품질속성(CQA)의 관계를 시각화하고, 정상·불량 배치의 패턴 차이를 파악하는 QbD의 출발점입니다.

실습 환경


gemini, GPU 제공
github.com
(코드/데이터 공유)
colab
(코드 실행)
구글 드라이브
(코드/데이터 백업)
작업 PC
LLM 코드작성:
claude, gemini

AI Model

- AI 구현의 핵심은, 데이터(X)로부터 원하는 출력(y)를 생성하는 모델(Model) SW 개발이다
- 수식은 가장 명쾌한 모델이나 생명현상을 포함한 복잡한 실제 세계를 모델링하는데 한계가 있다
- 데이터를 기반으로 동작하는 **Machine Learning Model**이 현재 AI 구현에 널리 사용되고 있다
  - 데이터: 학습 데이터, 검증 데이터, 테스트 데이터



AI Model 유형

예측 모델 Predictive Model	입력 데이터(X, feature)를 보고 출력(y, 레이블) 예측	X → Model → y
추천 모델 Recommender Model	최적의 상품·처방·후보 추천	X → Model → candidate
최적화 모델 Prescriptive Model	현재 조건(X)에서 최적 설계·제어 변수 도출	X → Model → control
표현 학습 Representation Learning	X를 학습하여 의미 있는 벡터 표현(embedding) 학습 → **파운데이션 모델(LLM), 분자 임베딩**	X → Model → vector
생성 모델 Generative Model	파운데이션 모델을 이용하여 원하는 데이터(X^) 생성 → **자연어 처리, 분자 생성 모델, 단백질 구조 생성**	X → Model → X^

AI 구현 체계

데이터

정형 데이터

텍스트

이미지, 동영상

센서

분자/단백질 표현형

데이터 전처리

x

머신러닝, 딥러닝 모델

Linear Model, SVM, Logistic Regression

Random Forest, Tree, Boost

MLP

CNN

RNN / LSTM

Graph Neural Net

Transformer

y

AI 목적

예측 (회귀, 분류)

추천

최적화

생성

표현 학습, 클러스터링

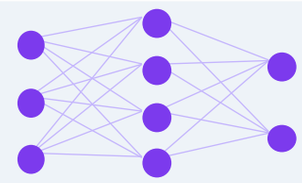
머신러닝 모델

머신러닝 유형		알고리즘	특 징
지도학습 (y가 존재)	선형 계열	선형 모델, SVM 로지스틱회귀	곱셈과 덧셈으로 점수를 구하고 이를 이용하여 회귀와 분류 예측
	신경망	MLP, CNN, RNN, Transformer Graph Network	매트릭스 연산을 기반으로 점수를 계산하며 활성화 함수 도입
	트리 계열	결정 트리, 랜덤포레스트, 부스팅	True/False 선택을 반복하여 회귀와 분류 예측 수행. 스케일링이 필요없다
	기타	kNN, 베이즈	특성 공간상의 거리를 기준, 또는 조건부 확률을 기준으로 예측
비지도학습 (y가 없음)	클러스터링	k-means, DBSCAN	특성 공간상 거리 또는 유사도를 기준으로 샘플을 그루핑
	데이터 변환	스케일링, 로그변환, 카테고리 인코딩	모델의 성능을 높이 위한 데이터 전처리
	차원 축소	PCA, t-SNE	계산량을 줄이고 모델 성능을 향상, 또는 시각화를 위한 차원 축소
	표현 학습	LLM 등 파운데이션 모델	입력 데이터를 latent vector로 표현하는 비지도 학습
강화학습		시행착오의 경험을 누적	샘플 입력마다 정답이 있지 않지만 최종적으로 달성해야 할 목표를 알려주고 보상을 통해 학습

딥러닝 모델

MLP

Multi Layer Perceptron. 완전 연결(Fully Connected) 레이어들의 다층 구조로 **비선형적인** 입출력 관계 예측에 주로 사용



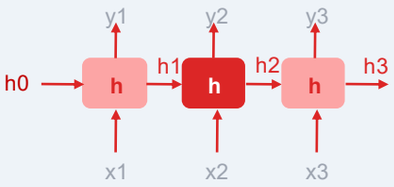
CNN

Convolution Neural Network. 2차원 이미지, 1차원 시계열 데이터의 **패턴 추출**에 주로 사용



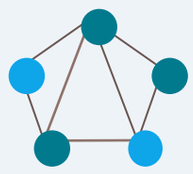
RNN (LSTM)

Recurrent Neural Network (Long Short Term Memory). 순환 구조로 **시퀀스 데이터**· 텍스트 분석 · SMILES 분석 등에 활용



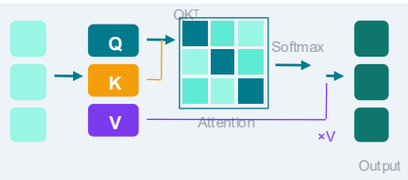
Graph Model

노드와 엣지로 구성된 그래프 형태의 모델로 **분자 구조**, 사회관계망 등의 분석에 사용



Transformer

입력 시퀀스를 블록 단위로 나누어 Self-Attention을 계산하는 방식으로 텍스트, 시퀀스 데이터의 **문맥 파악** 성능을 향상. LLM의 성능 고도화 (BERT, GPT)



데이터 전처리

- 데이터 정제 (cleaning)
  - 빠진 값을 처리하거나 오류를 수정하는 것
- 이상치 처리
  - 비정상적으로 튀는 값(이상치)을 찾거나 제거하는 것
- 데이터 변환 (transformation)
  - 로그, 역수, 승수, 카테고리 변수를 적용하는 것
- 스케일링 (scaling)
  - 여러 데이터의 특성 값의 범위를 동일한 조건으로 조정하는 것
- 특성 선택과 차원 축소
  - 특성 중 일부를 선택하거나 특성을 조합하여 새로운 특성을 만드는 것
  - 주성분 분석(PCA): 머신러닝에 사용할 특성의 수를 줄이는 것
    - Principal components analysis

표현 학습

표현 (Representation)

X				y
이름	키	몸무게	나이	운동종목
A	178	73	34	축구
B	169	72	38	탁구
C	173	68	52	농구
…	…	…	…	…
Z	175	82	29	배구

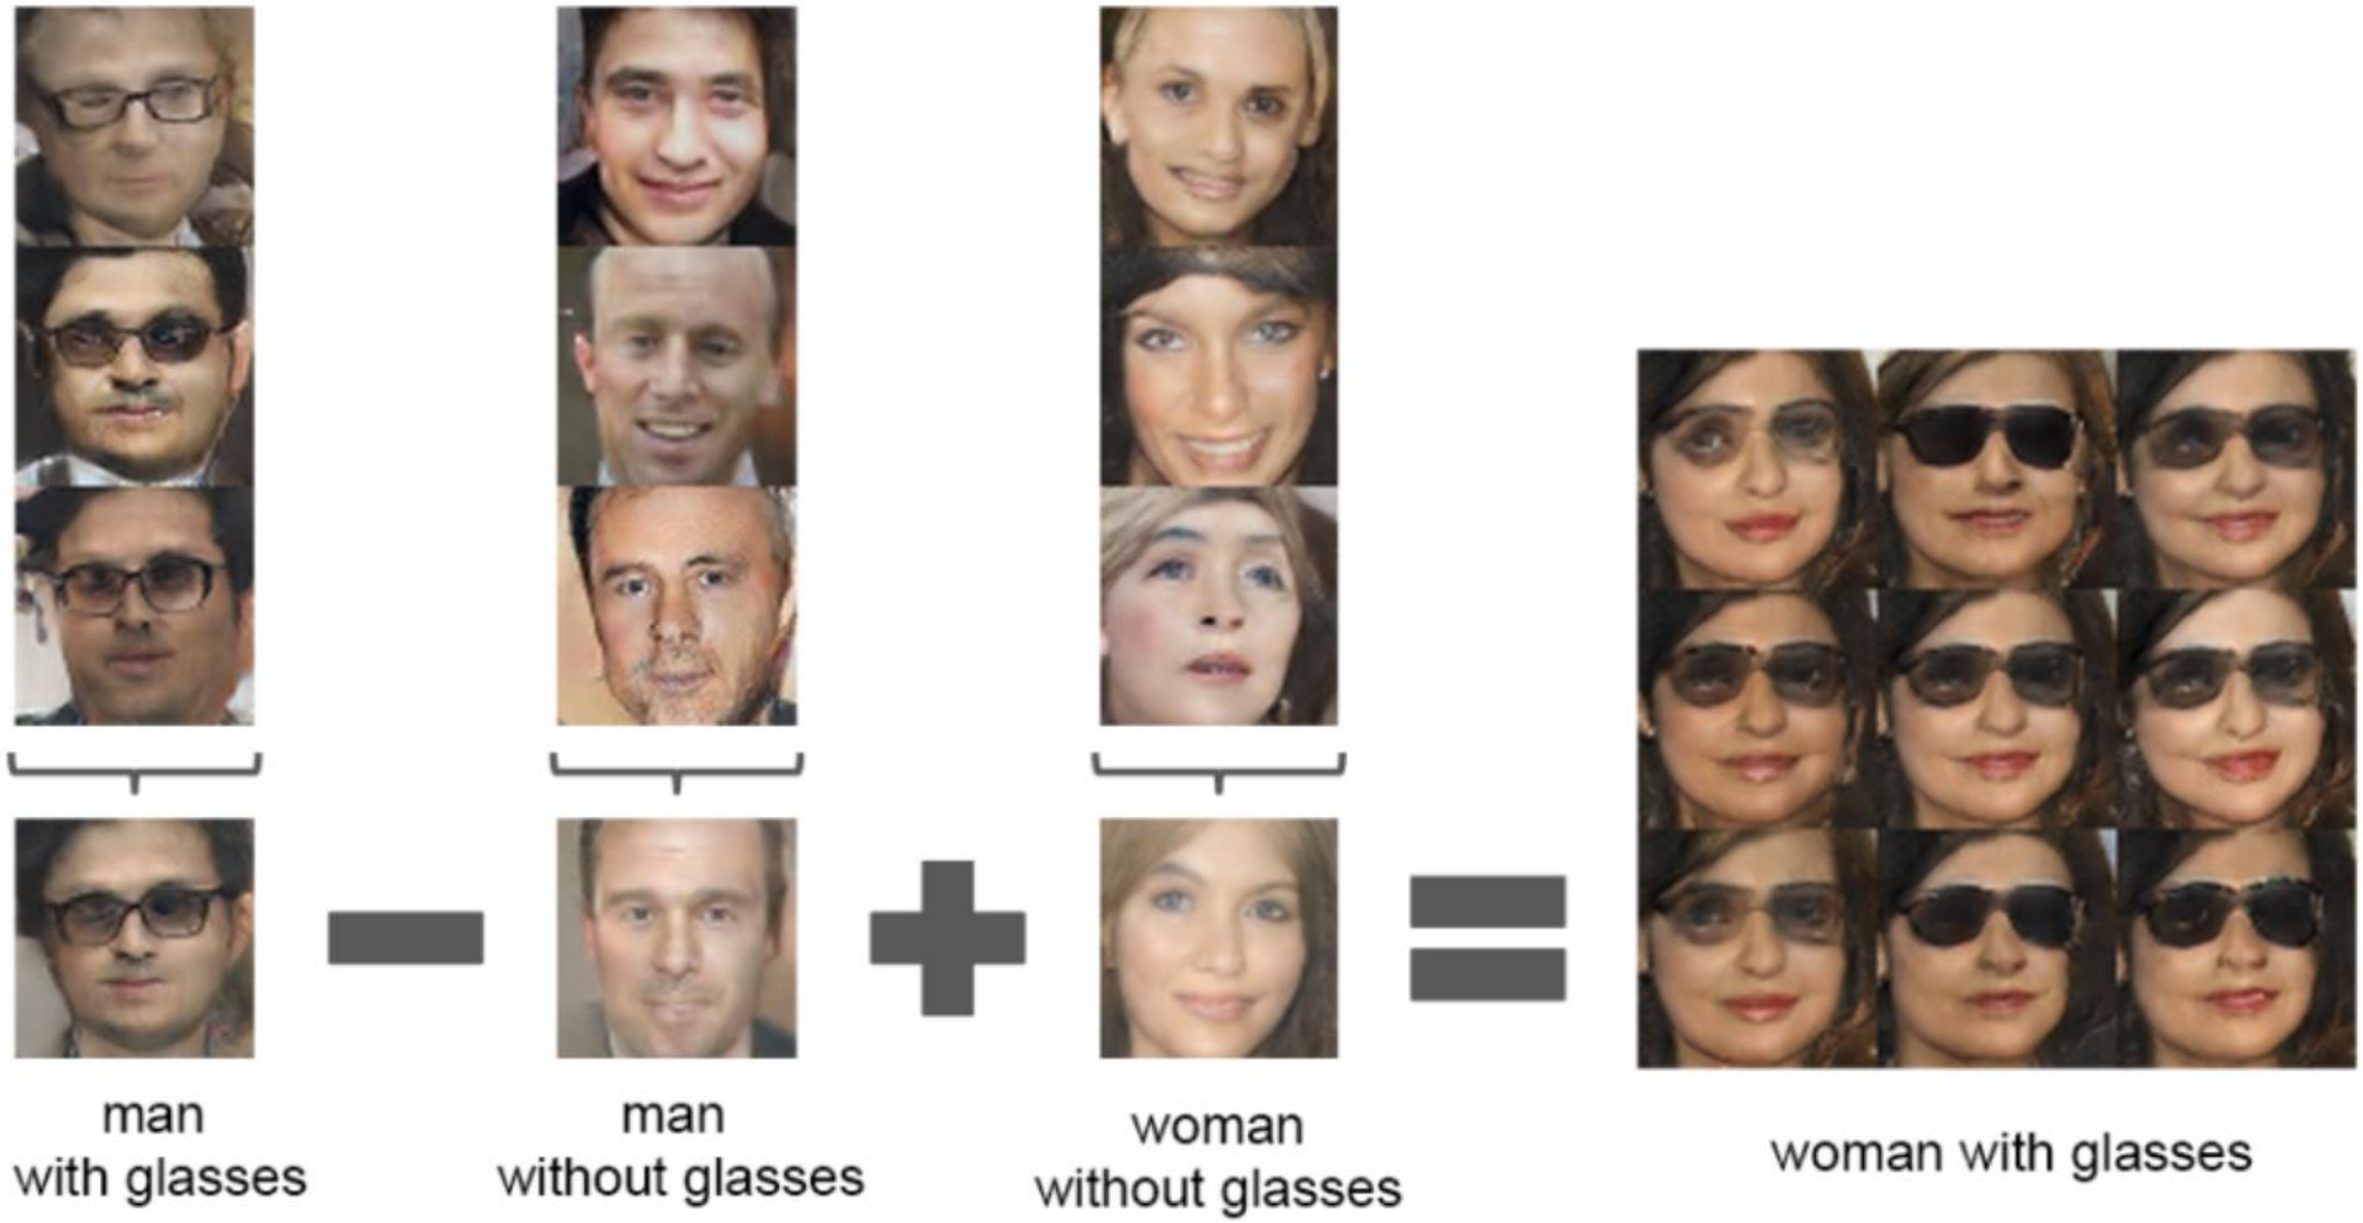
- X: features, 설명변수, 독립변수, 입력 → **표현(representations)**
- y: label, 목적변수, 종속변수, 출력

Image Representation



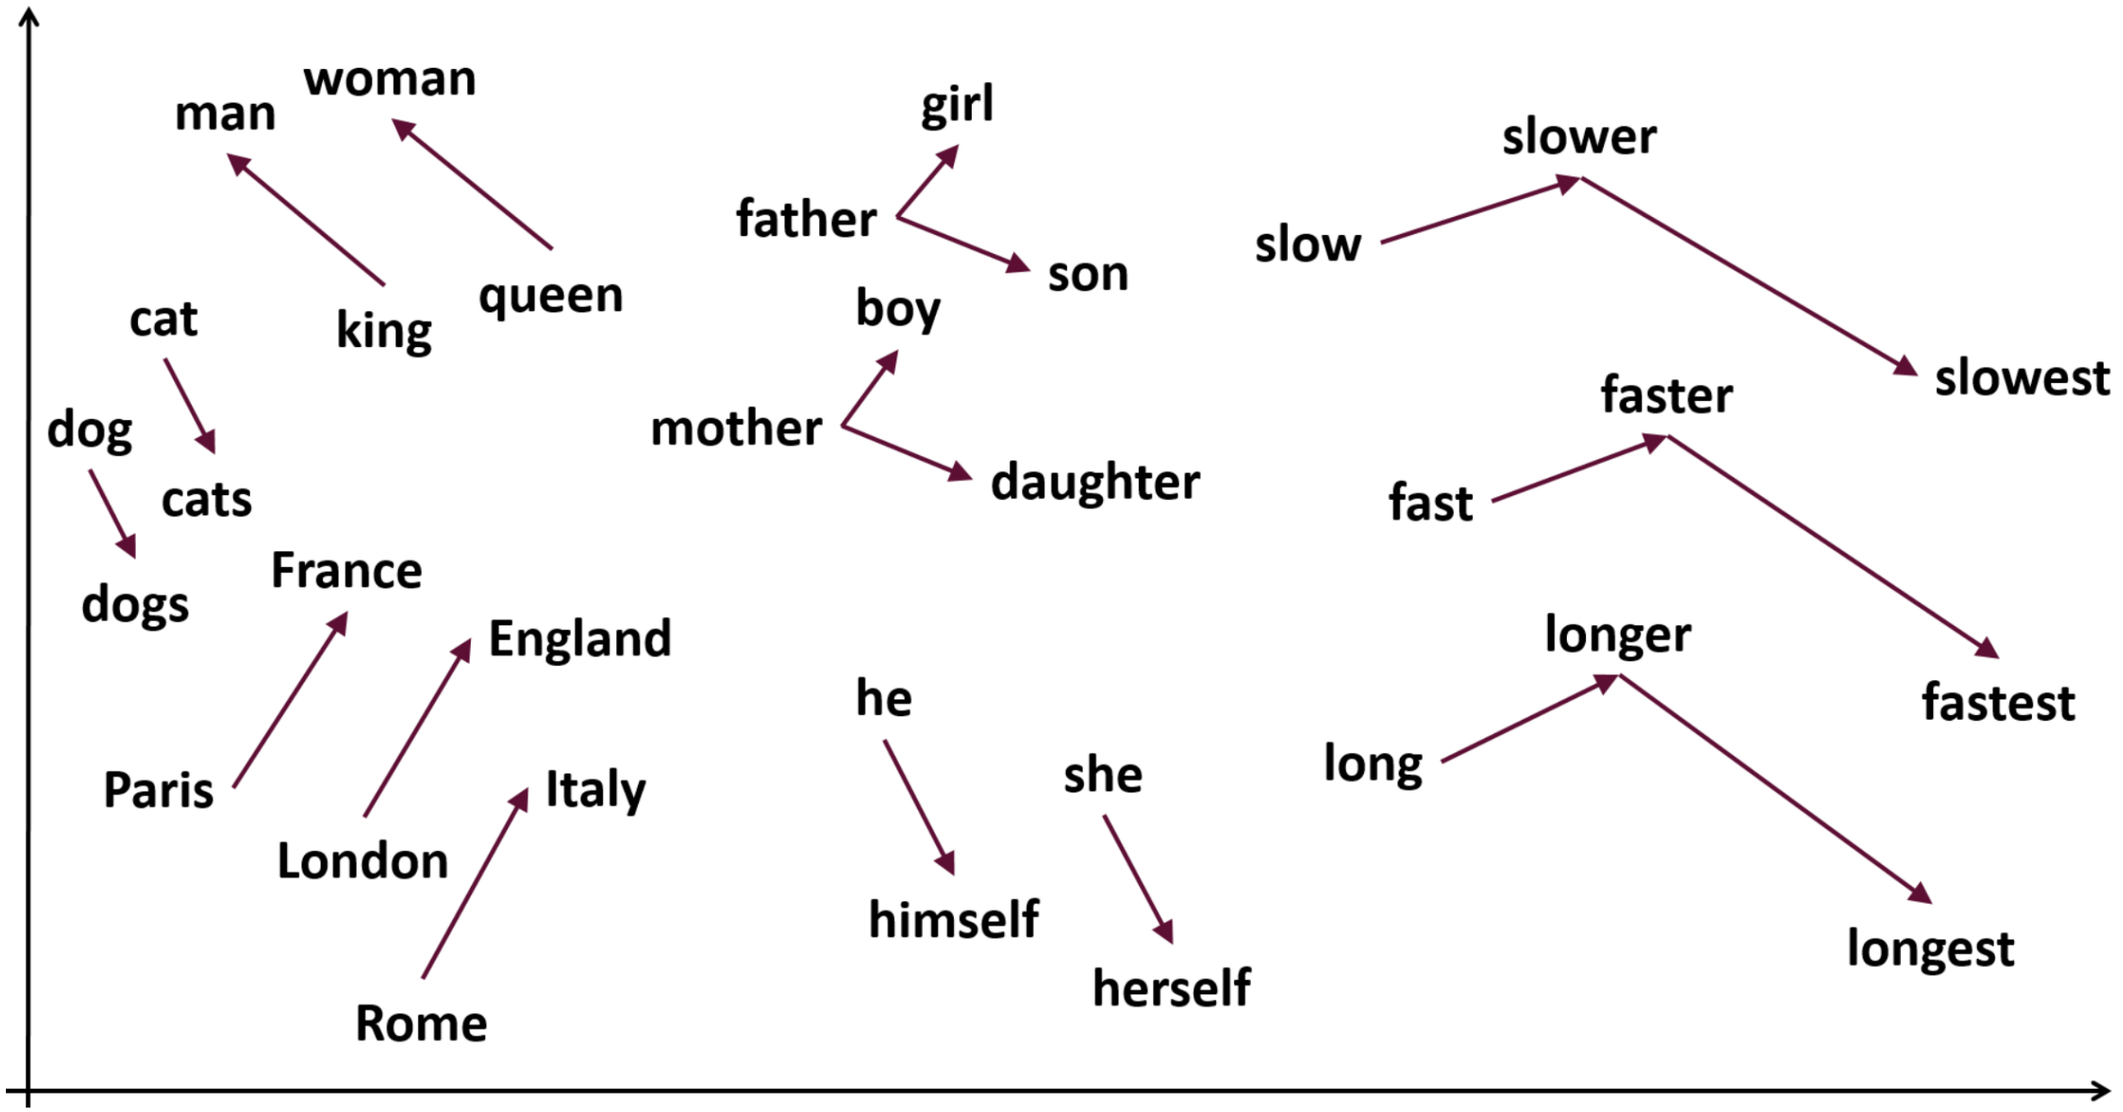
- 몽타주는 이미지를 수십개의 features(숫자)로 표현하는 것
  - 안경:0, 눈썹길이:0.8, 눈썹모양: 2, 코:0.7, 입술:0.4, 턱: 0.4, 귀:3,…
- 얼굴 = (0, 0.8, 2, 0.7, 0.4, 0.4, 3, …, 0,6) : vector
  - → 이미지를 임베딩 벡터로 표현 가능
  - → 벡터 **차원을 높이면** 매우 정교하게 얼굴을 묘사할 수 있다
  - → 벡터 **값을 바꾸면** 다른 얼굴을 표현할 수 있다 (이미지 생성 모델)

이미지 임베딩 벡터 연산


man
with glasses
man
without glasses
woman
without glasses
woman with glasses

Word Representation

- word embedding vector 표현 (300~1000 차원 사용)
- 단어 사이의 **거리**가 의미가 있다
- 단어 간의 **방향**이 의미가 있다



분자 표현법

- SMILES (Simplified Molecular-Input Line-Entry System)
  - Cn1cnc2N(C)C(=O)N(C)C(=O)c12 과 같이 분자를 문자열로 표현
- Descriptors
  - 몰질량, 구성 원자, 분배계수, 극성표면적 등 분자를 기술하는(describe) 수치 데이터들을 특성(feature)으로 사용(테이블 구조)
- Fingerprints
  - 분자가 가지고 있는 여러 특성 유무를 1, 0 패턴으로 표현 (화학적 지문)
  - 두 분자의 속성이 유사하면 fingerprints의 1, 0 발생 패턴이 유사
- Graph based

Descriptor Based

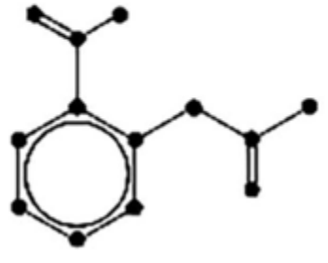
Molecule	Features				Property
...	F_{10}	F_{11}	...	F_{1N}	...
...	...	...	...	...	...
...	...	...	...	...	...
...	F_{21}	F_{22}	...	F_{MN}	...

Fingerprints

[0 0 0 1 ... 0 0 0 0 1]



Graph Based

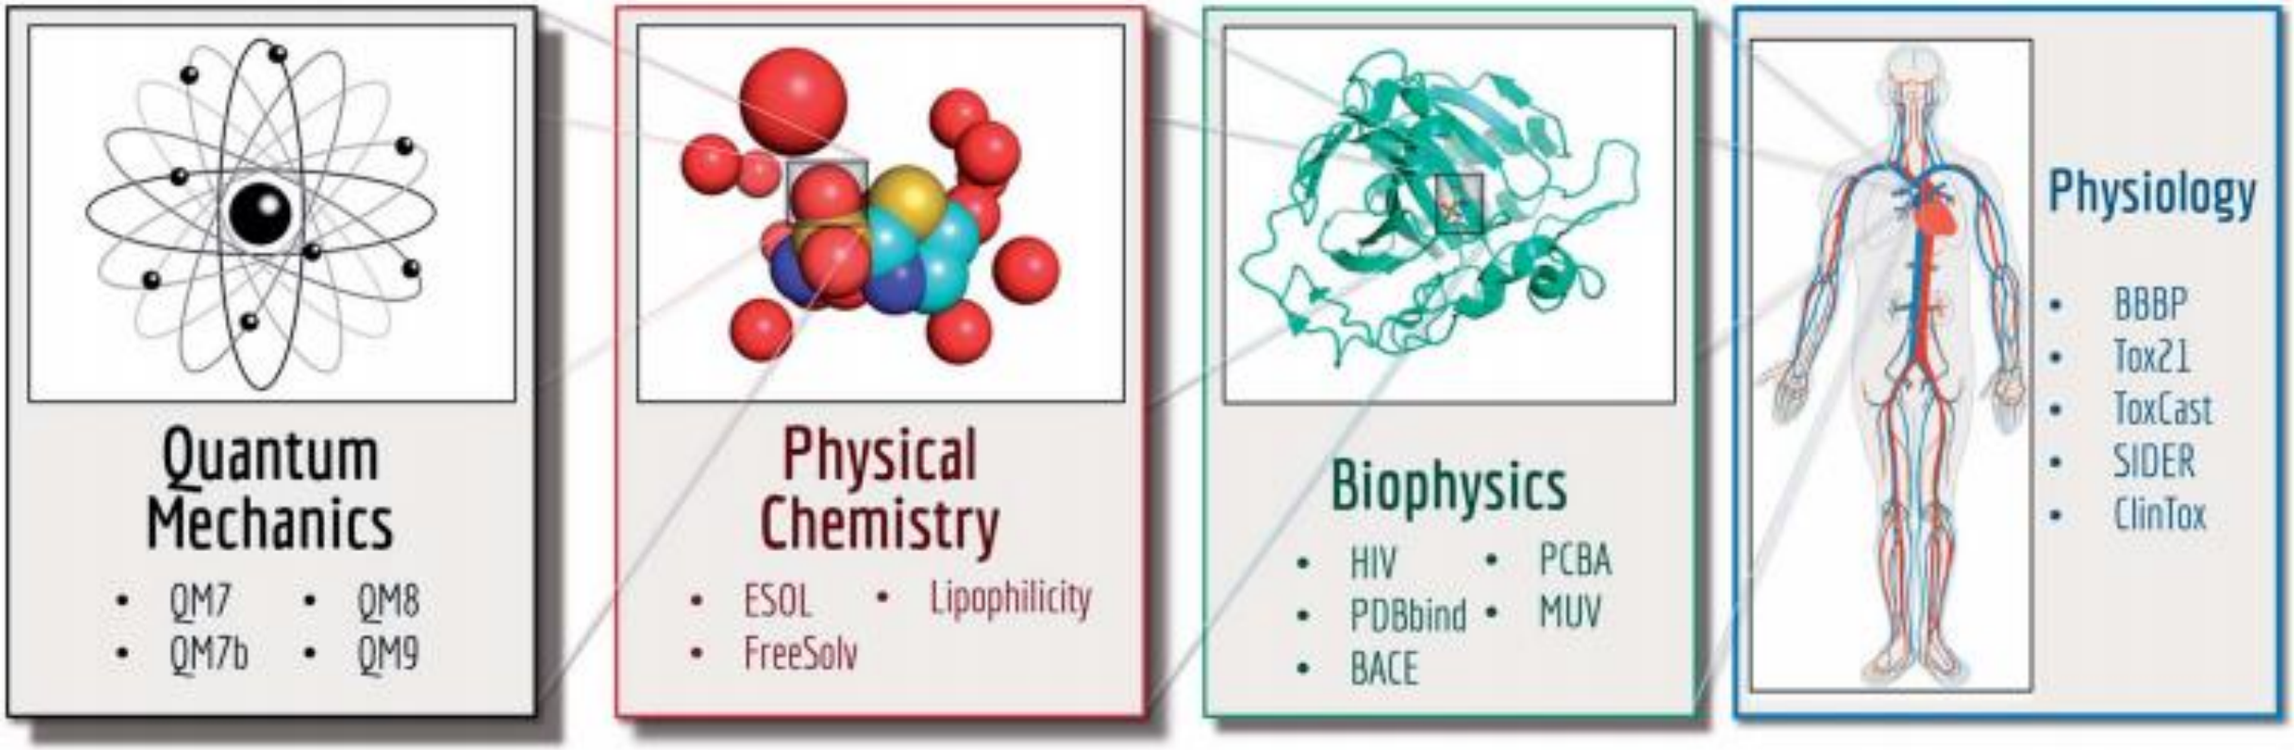


화합물 Datasets

- PubChem
  - By National Institutes of Health from 2004 (non-curated)
  - 가장 규모가 크다 (거의 모든 화합물 정보를 포함)
  - curated dataset of 77 million SMILES
- ChEMBL
  - manually curated (and so high-quality) public database of bioactivity data
  - 1.9 m compounds, 12,000 targets from 1.1 M assays
- ZINC
  - by UCSF
  - molecules, annotated ligands and targets as well as the purchasability for 120 million "drug-like" compounds
  - 부분 데이터: ZINC-250k, ZINC Clean Leads collections

MoleculeNet

- 학습용 분자 데이터셋 (tox21, delany 등)
  - 양자물리학, 물리화학, 생물물리학, 생리학 등 범위의 데이터 제공
- ESOL 수용성 용해도, BBBP 투과성 예측 등



손실함수와 성능지표

- **손실함수**(loss function)는 모델을 훈련시킬 때 기준으로 삼기 위해서이다.
  - 모델은 손실함수를 최소화 하는 방향으로 학습한다
- **모델의 성능지표**는 이렇게 만든 모델이 궁극적으로 얼마나 잘 동작하는지를 평가하는 척도이다

회귀모델의 손실함수

- 회귀분석에서는 오차 자승의 합의 평균치(MSE: mean square error)를 손실함수로 주로 사용한다

$$\mathrm{MSE} = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

  - N: 배치 크기

- 배치 크기, 학습률과 같은 설정 변수를 하이퍼파라미터라고 한다
  - **하이터파라미터**는 사람이 선택하는 값이며, 머신러닝 모델이 최적화 해야 하는 계수는 "**파라미터**"이다

회귀 성능 평가 지표

- 회귀모델의 성능 평가에는 R-squared가 사용된다.
- R-Sqaured,

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2}$$

- 위에서 y_i 는 실제 값, $\hat{y}_i$ 는 예측 값, $\bar{y}$ 는 샘플의 평균 값을 나타낸다
- 완벽한 회귀 예측 모델은 R^2 값이 1이 된다

분류의 성능지표

- 분류에서는 정확도(accuracy)를 기본으로 측정하나 필요에 따라 다음과 같은 값을 추가로 측정해야 한다
- 컨퓨전 매트릭스를 사용한다
  - 정밀도 (precision)
  - 재현률 (recall)
  - F-1 점수
  - ROC
  - AUC

혼돈 매트릭스

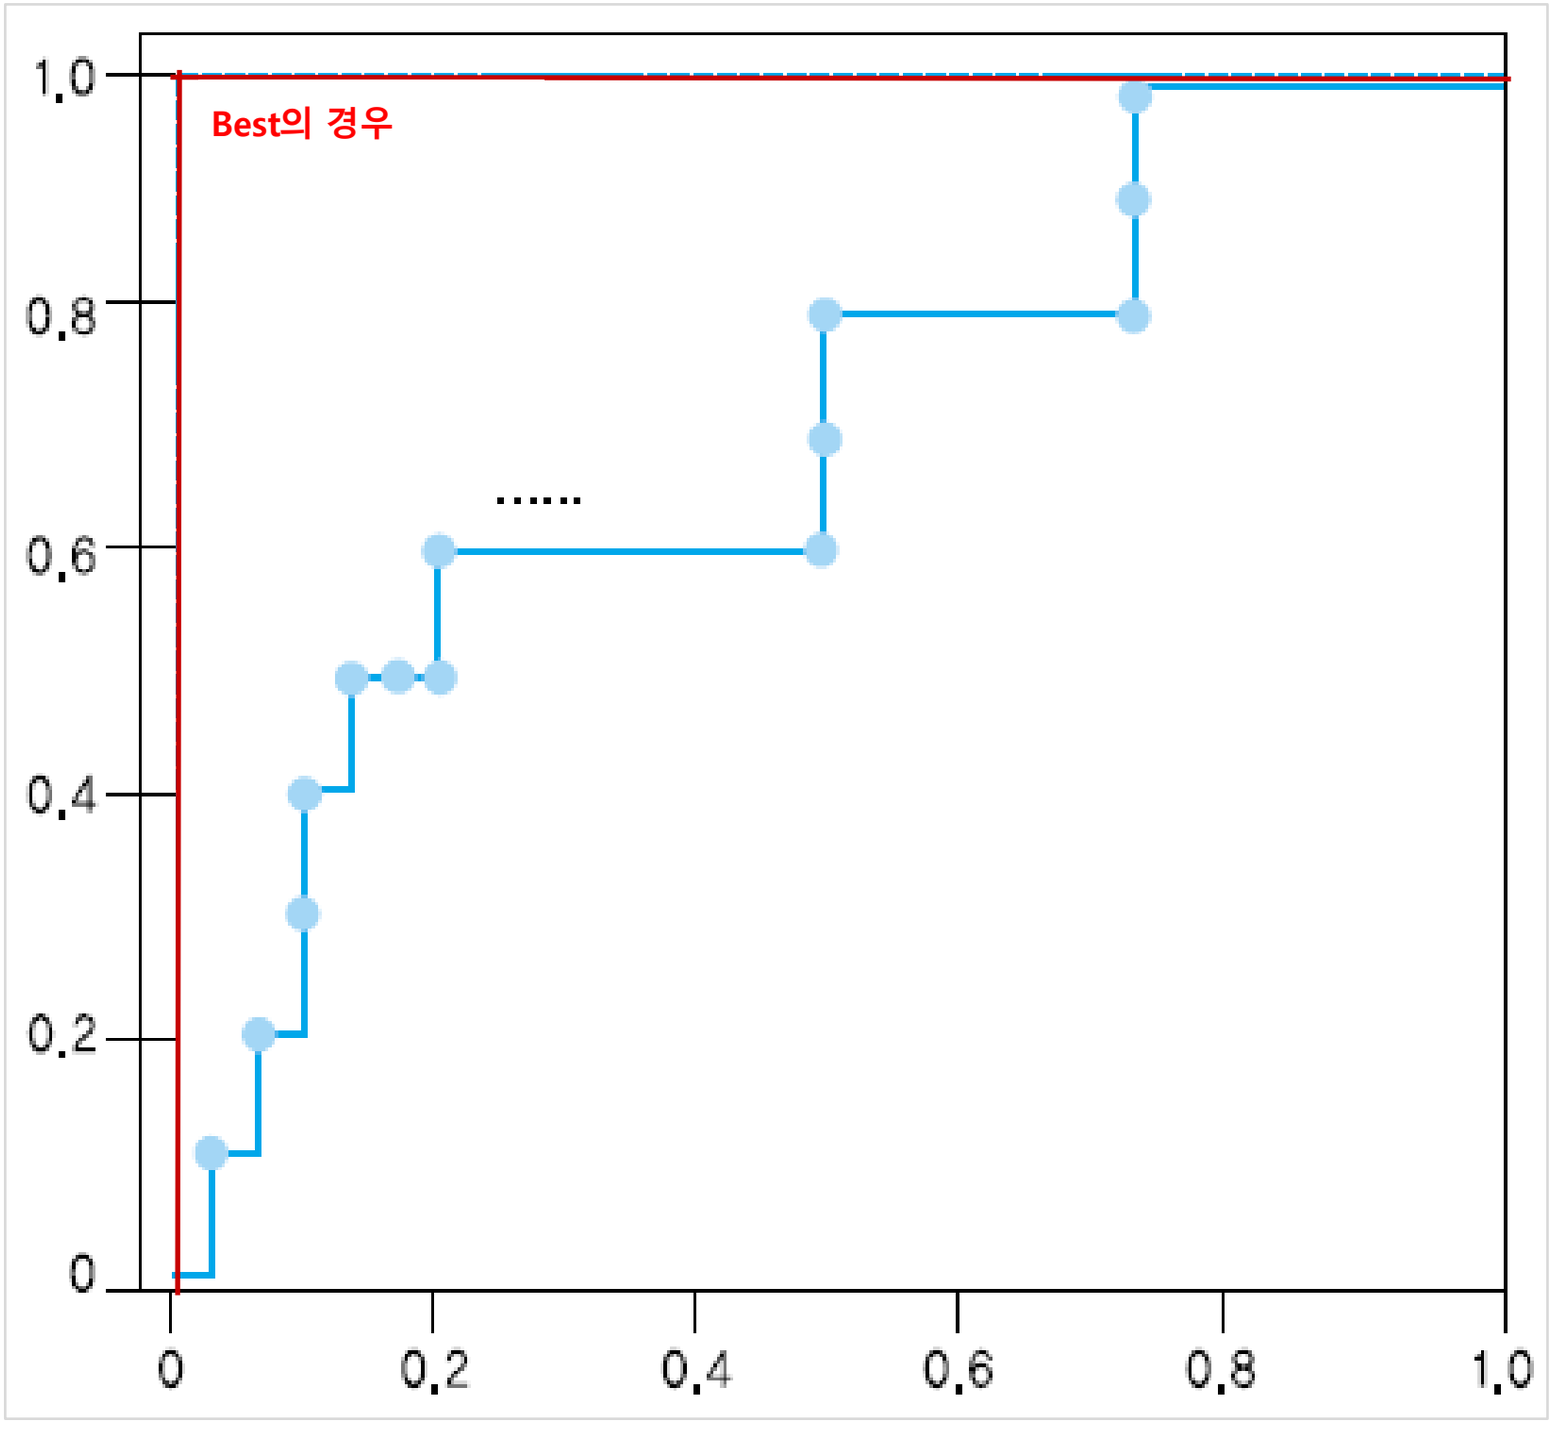
- 혼돈 매트릭스(confusion matrix)란 분류의 결과가 잘 맞았는지를 평가하는 채점표와 같다
- 이진 분류의 경우 네 가지 경우의 수가 존재한다.

실제 \ 예측	p로 예측	n으로 예측
실제로는 p	True positive (TP)	False negative (FN)
실제로는 n	False positive (FP)	True negative (TN)

실제 \ 예측	p로 예측	n으로 예측
실제로는 p	7	3
실제로는 n	10	80

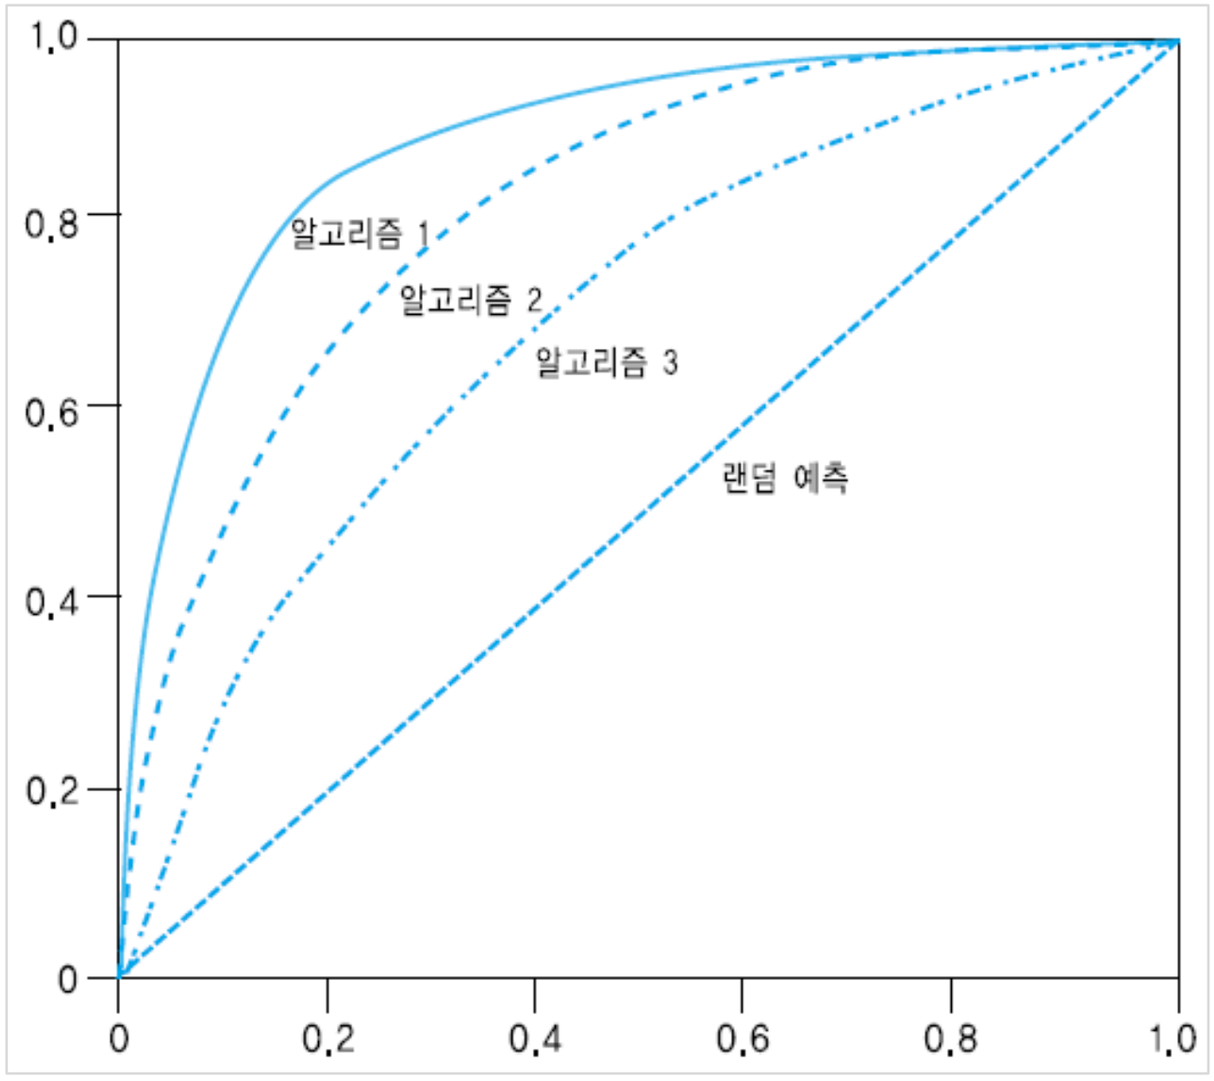
- accuracy= (6+80)/100=0.86, recall=(7/10)=0.7, precision=(7/17)=
  F1-score: recall과 precision의 조화 평균

ROC 그래프 예시



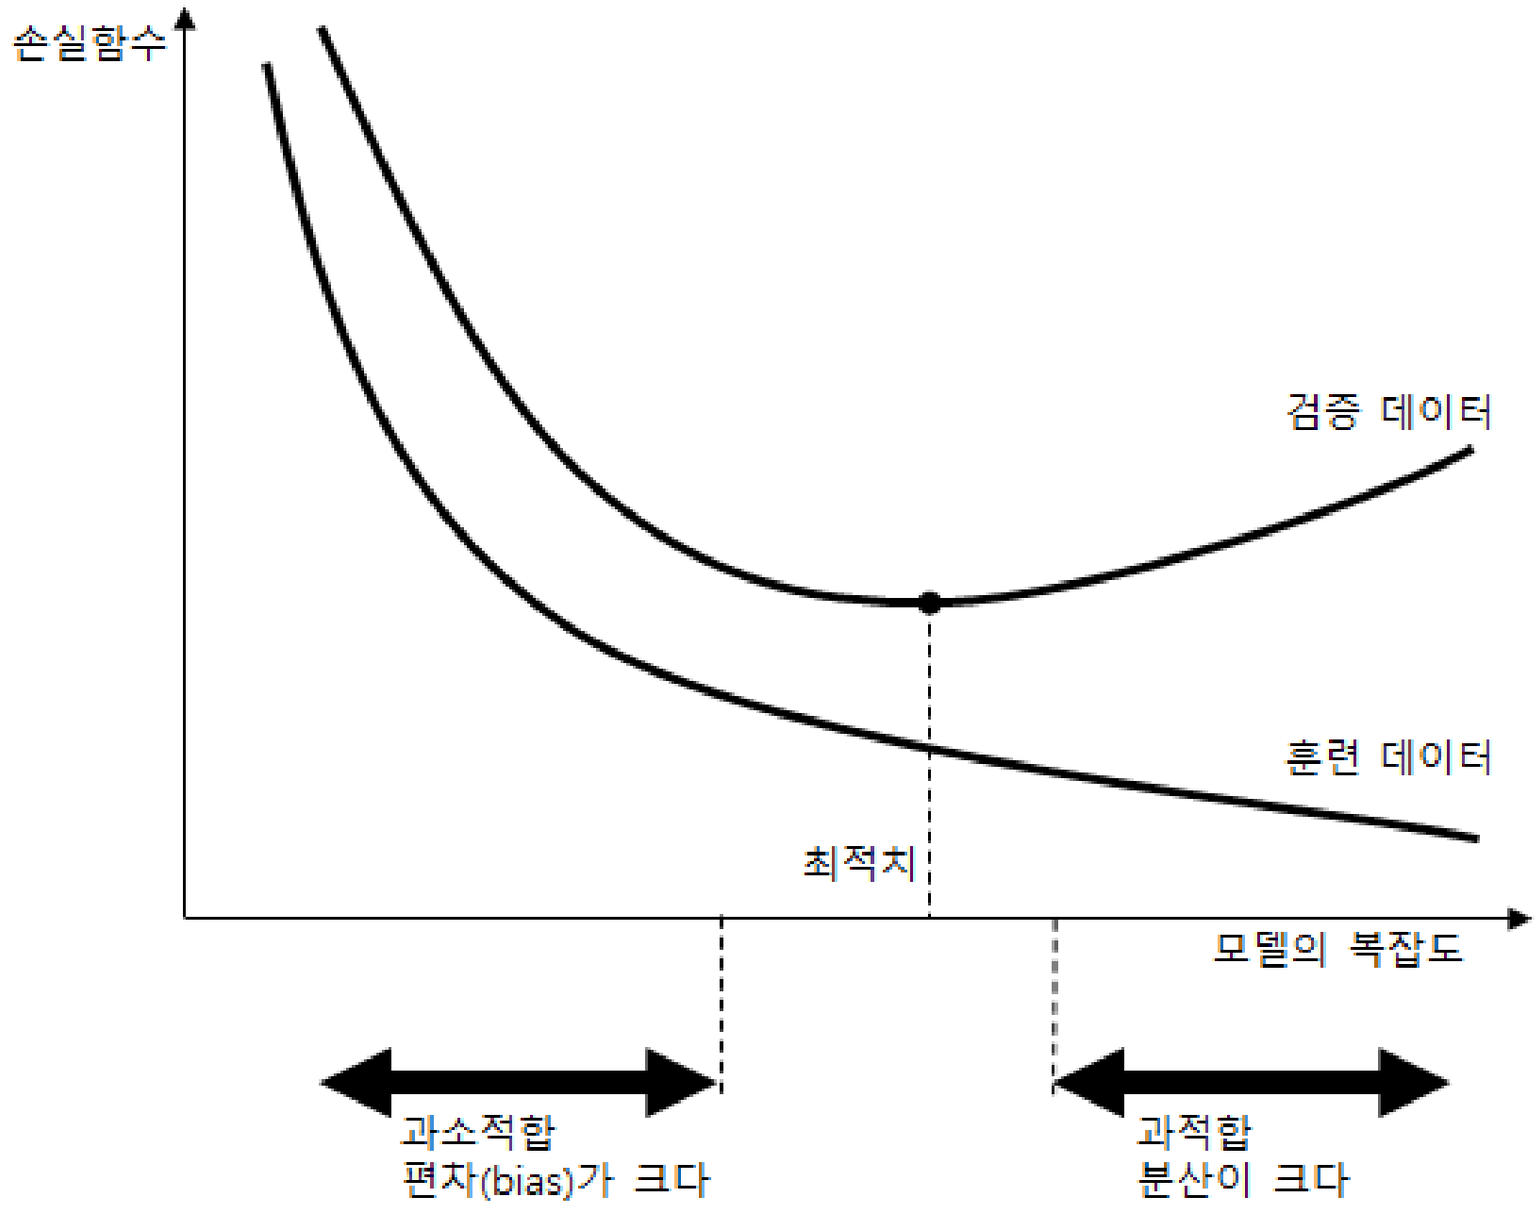
AUC(Area Under Curve)

- ROC 그래프의 면적을 계산
- 우수한 알고리즘일수록 초반에 y축 상단 방향으로 이동하므로 ROC 커브의 면적이 넓어짐



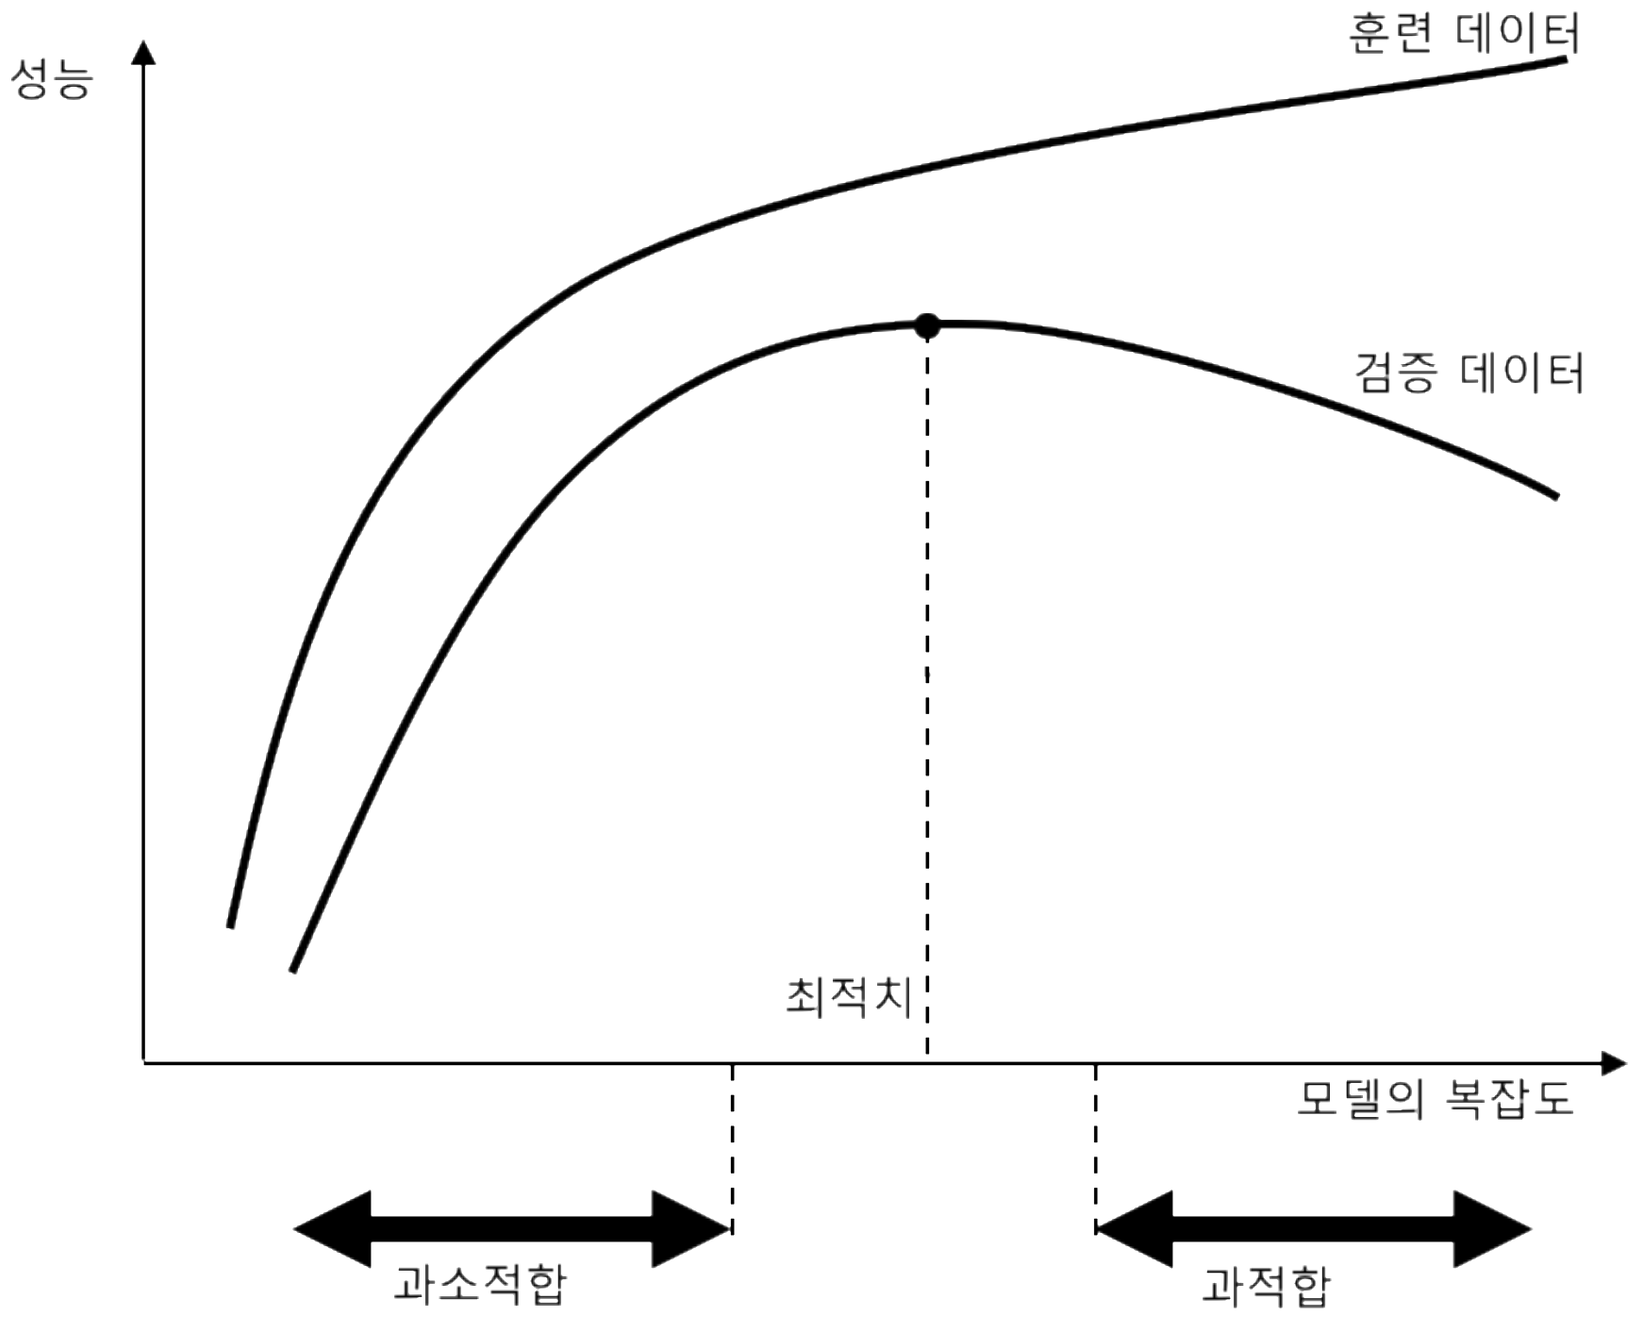
과대적합 검증

- 훈련 데이터에 대한 성능과 검증 데이터에 대한 손실함수를 관찰한다



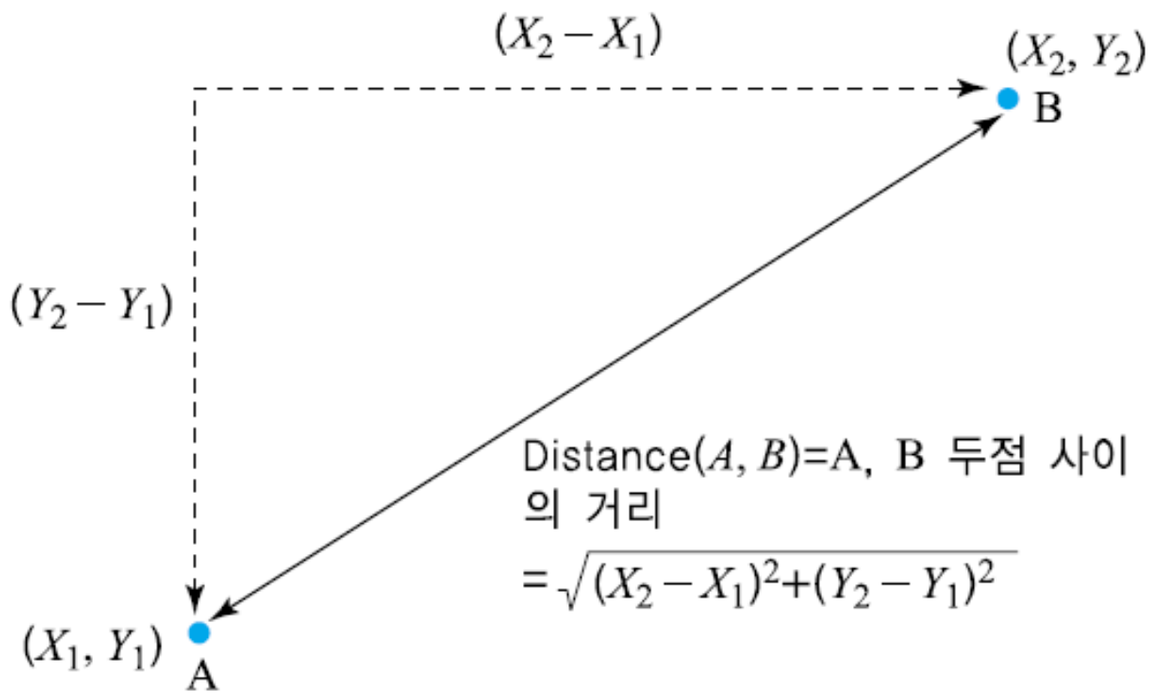
과대적합 검증

- 성능 비교



유클리디언 거리

- 기하학의 공간(space) 상의 직선 거리
  - 유클리디언 (Euclidean) 거리

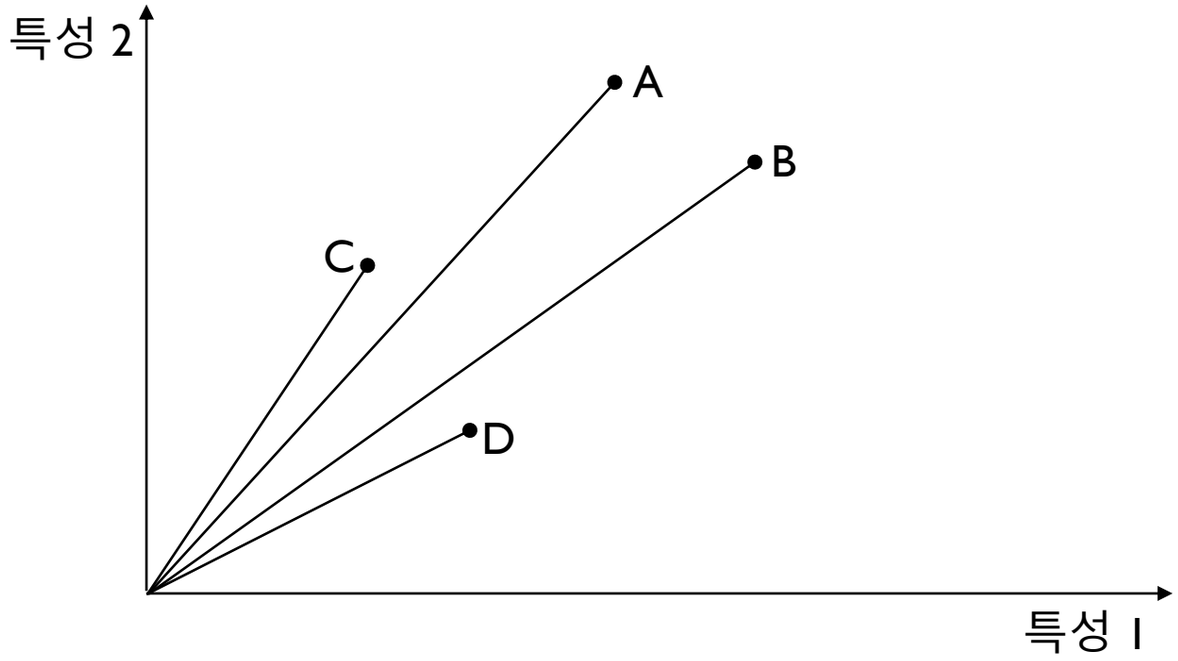


- n 차원 공간상의 두 점의 거리

$$\sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \ldots + (p_n - q_n)^2} = \sqrt{\sum_{i=1}^{n} (p_i - q_i)^2}$$

코사인(cosine) 유사도

- 공간상의 두 점이 만드는 각도를 기준으로 유사도를 측정하는 방법 (-1 ~ +1 사이의 값을 갖는다)
- 공간상 거리가 멀어도 두 점이 가리키는 방향이 같으면 서로 비슷하다고 보는 것



$$s_{\cos}(x,y) = \frac{X \bullet Y}{|X||Y|}$$

- A와 C가 가깝고 B와 D가 가깝다고 정의

자카드 유사도

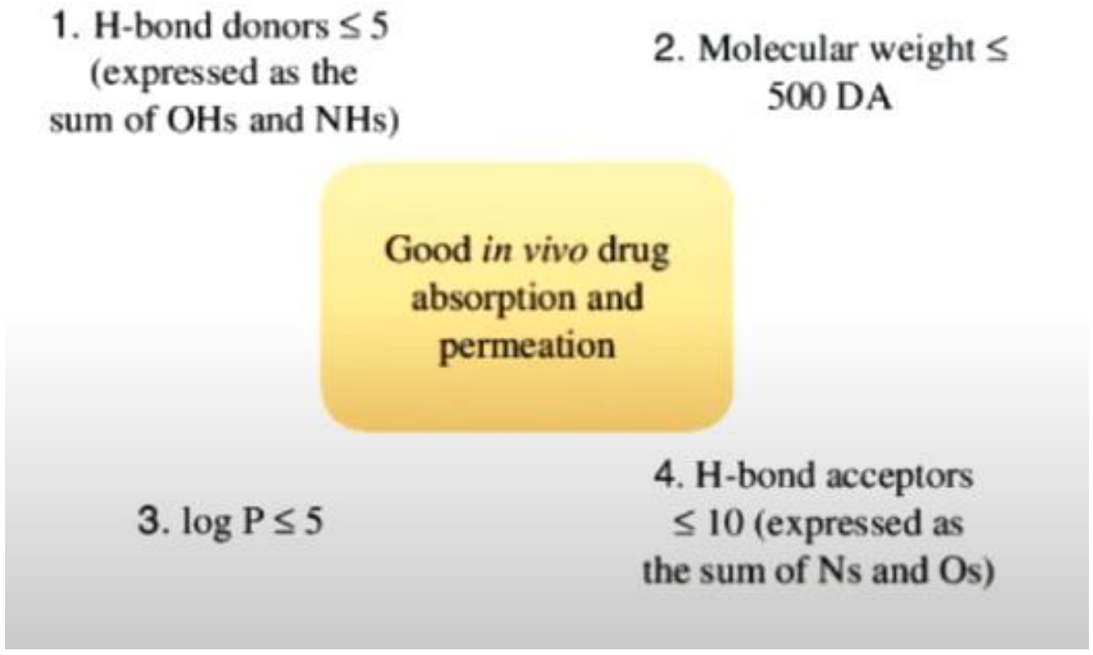
- 어떤 두 항목이 겹치는 부분의 절대량만을 보지 않고, 두 항목의 공통 부분이 얼마나 많은지를 고려하여 이에 대한 상대적인 값을 유사도로 사용하는 것

$$S_{Jaccard}(X, Y) = \frac{|X \cap Y|}{|X \cup Y|}$$

- A, B, C가 각각 지난해 본 영화의 총 개수가 20편, 50편, 200편
- J(A,B) = 5 / (20+50-5) = 0.076
- J(A,C) = 10 / (20+200-10) = 0.047
- 즉, 0.076 > 0.047이므로 A와 B가 더 가깝다고 할 수 있음

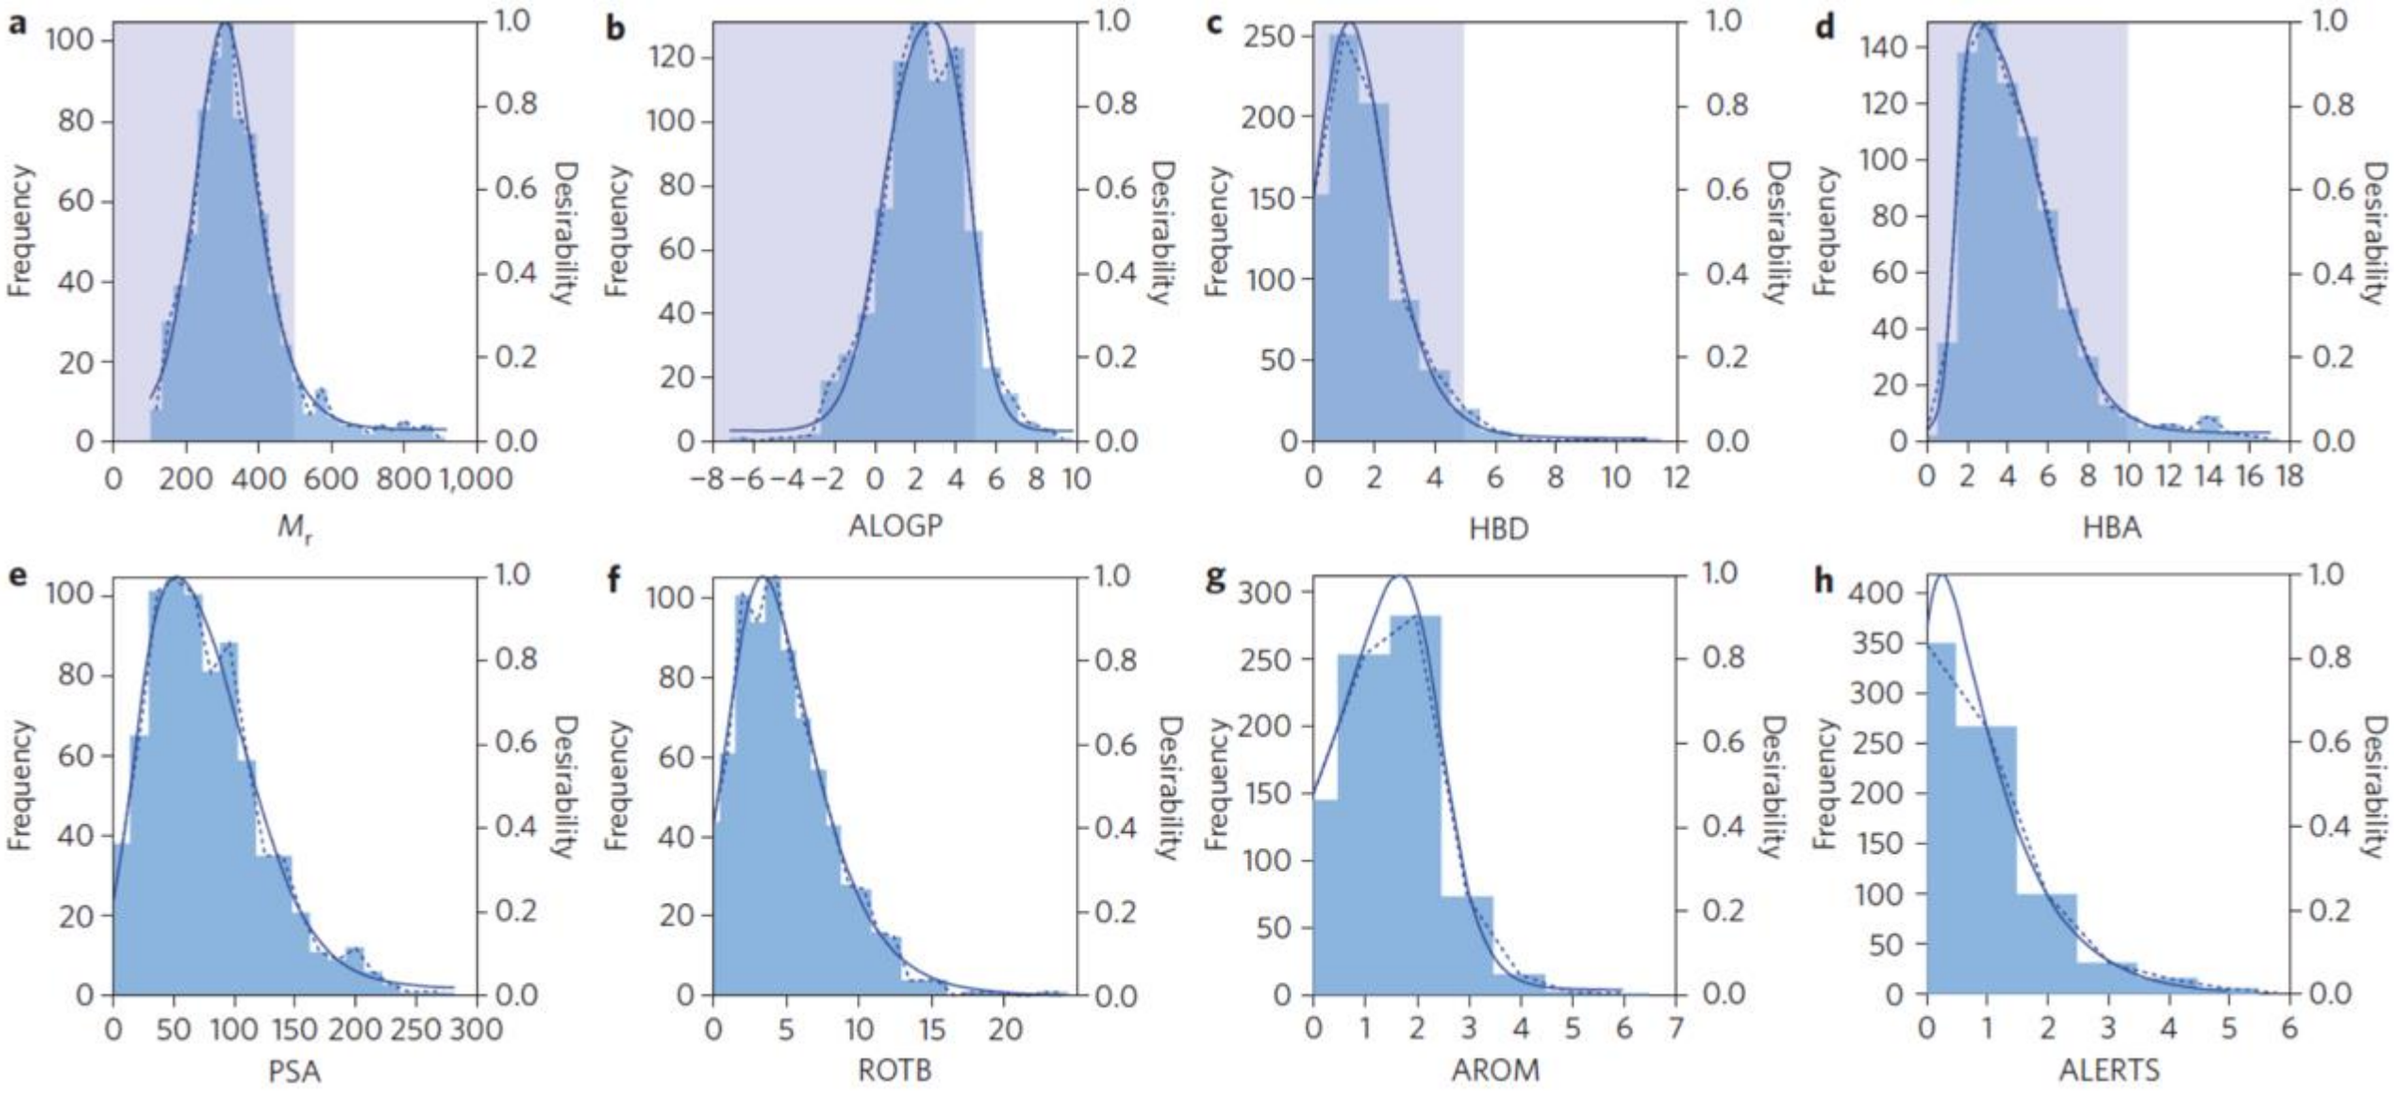
Lipinski's Rule-of-5

- Lipinski Rule (1997)
  - 구강투여될 만한 화합물인지 판단 (drug-like)
  - World Drug Index에서 2245개 화합물로부터 추출 (90%가 해당)
- Poor absorption or permeability when:
  - LogP (water partition coefficient, a measure of lipophilicity) is >5
  - molecular mass is >500 Da
  - the number of hydrogen-bond donors (OH plus NH count) is >5
  - the number of hydrogen-bond acceptors (O plus N atoms) is >10



QED

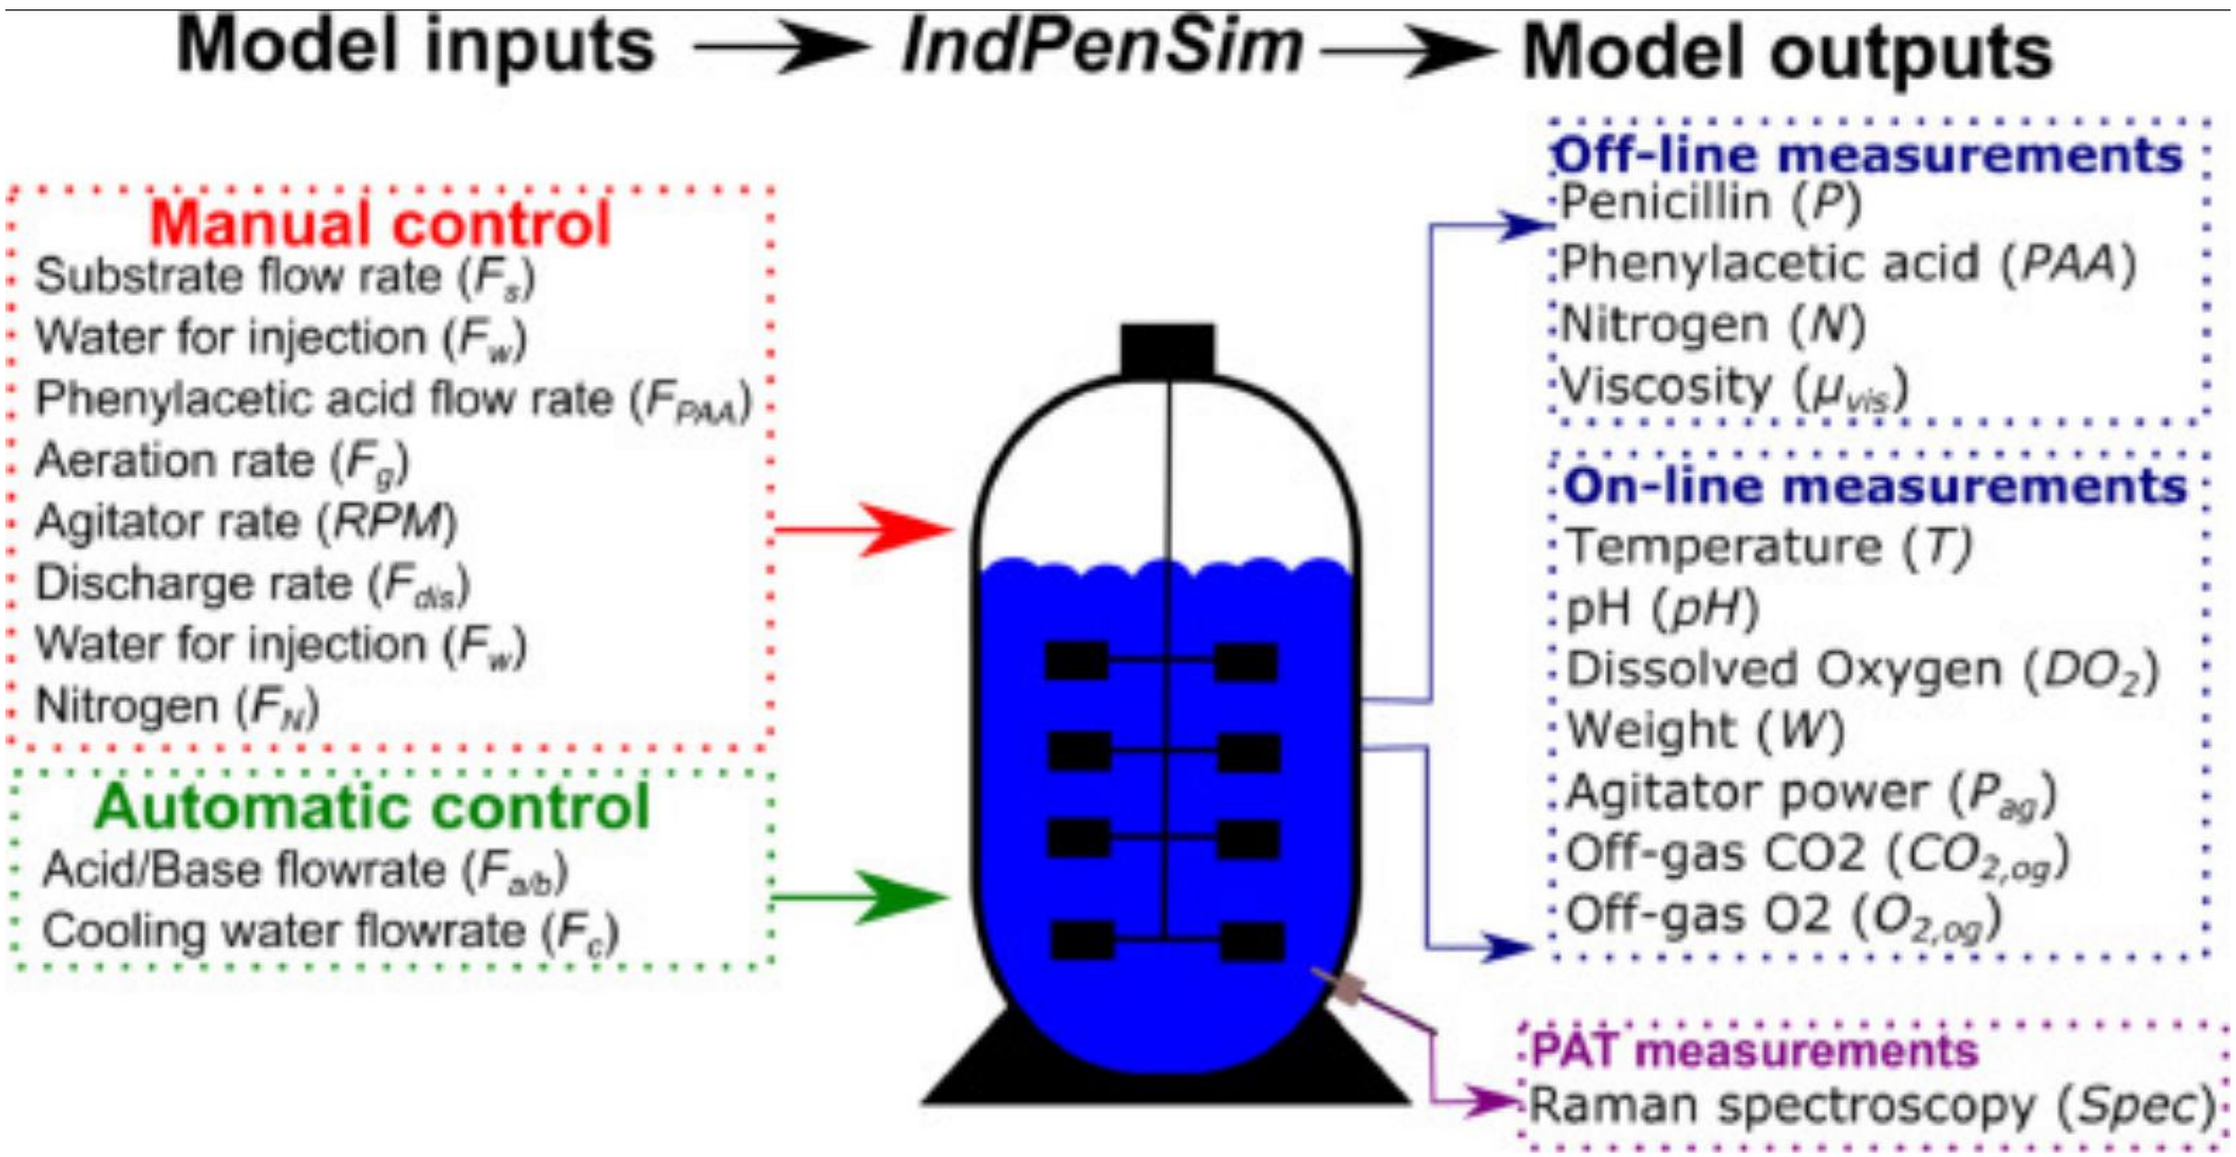
- Quantitative Estimate of Drug-likeness (2012)
- From molecular properties for small molecule drugs



Penicillin Fermentation Data

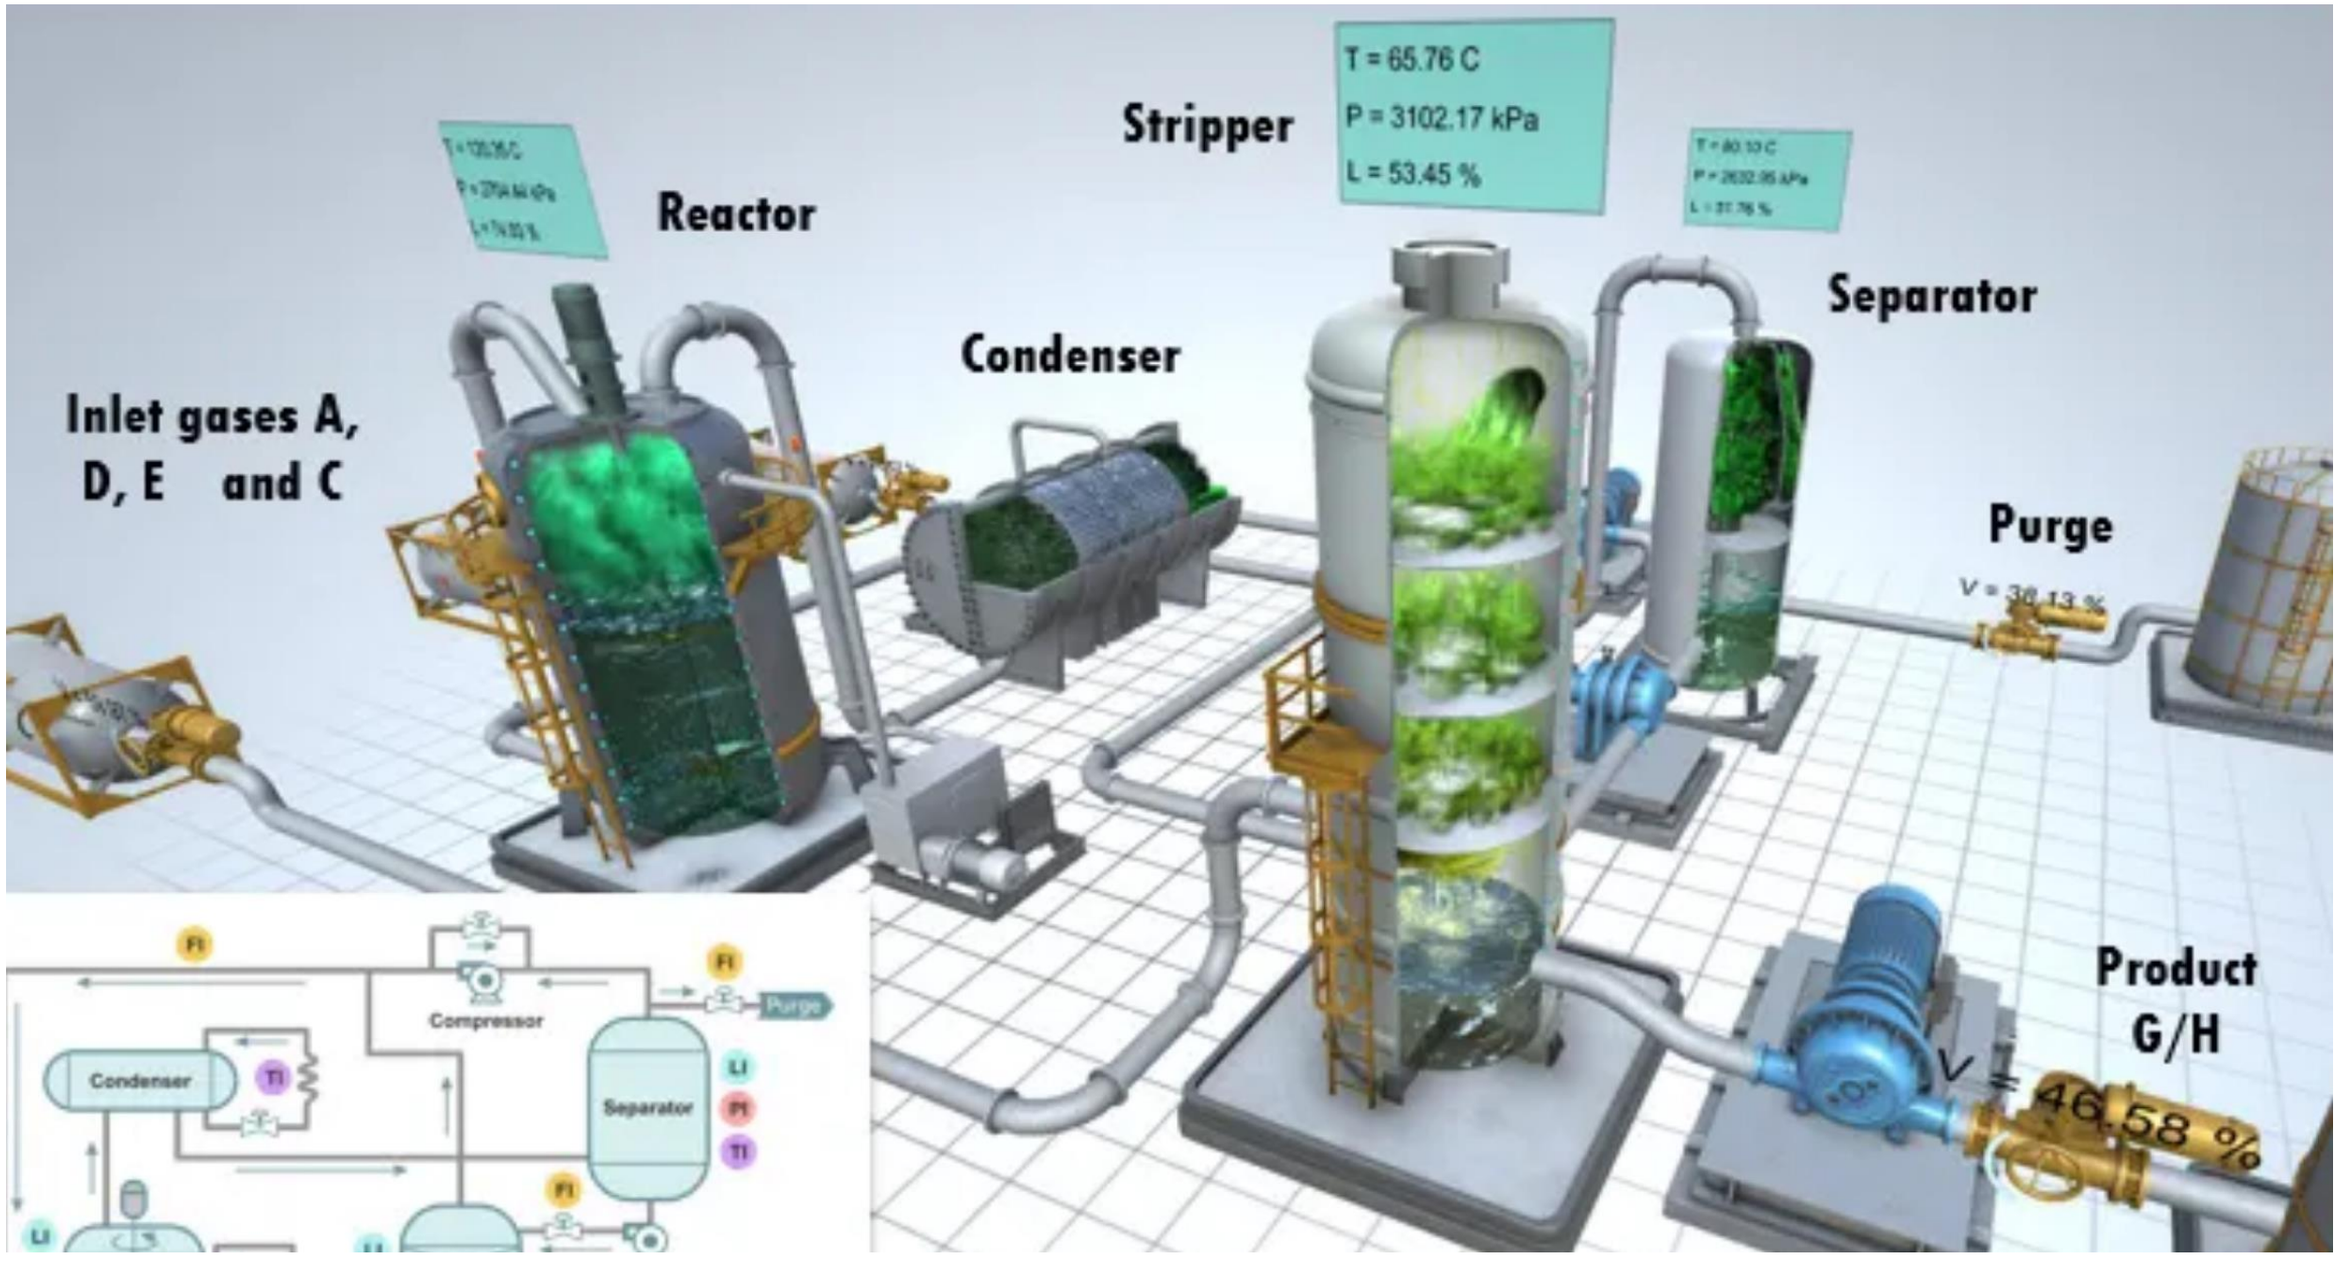
- IndPenSim (Industrial Penicillin Simulation)
  - 100,000리터(100톤) 규모의 산업용 바이오 리액터(Bioreactor) 모델링, Upstream Process 배치 공정 예제
- 생물학적 반응(미생물 성장)
  - 데이터가 비선형적
- 입력(제어 변수)
  - 교반 속도(Agitation), 공기 주입량(Aeration), 기질 투입 속도(Feed Rate), temperature
- 출력(상태 변수)
  - pH, 용존 산소량(dissolved oxygen), 이산화탄소 배출량, 페니실린 농도(Product) 등

- Batches 1-30: Controlled by recipe driven approach
- Batches 31-60: Controlled by operators
- Batches 61-90: Controlled by an Advanced Process Control (APC) solution using the Raman spectroscopy
- Batches 91-100: Contain faults resulting in process deviations


Model inputs
IndPenSim
Model outputs
Manual control
Substrate flow rate (F_s)
Water for injection (F_w)
Phenylacetic acid flow rate (F_{PAA})
Aeration rate (F_g)
Agitator rate (RPM)
Discharge rate (F_{dis})
Water for injection (F_w)
Nitrogen (F_N)
Automatic control
Acid/Base flowrate ($F_{a/b}$)
Cooling water flowrate (F_c)
Off-line measurements
Penicillin (P)
Phenylacetic acid (PAA)
Nitrogen (N)
Viscosity (μ_{vis})
On-line measurements
Temperature (T)
pH (pH)
Dissolved Oxygen (DO_2)
Weight (W)
Agitator power (P_{ag})
Off-gas CO2 ($CO_{2,og}$)
Off-gas O2 ($O_{2,og}$)
PAT measurements
Raman spectroscopy ($Spec$)

Tennessee Eastman Process

- A simulated chemical plant data
  - Designed for process control and fault detection research



Q & A